

**TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG
KHOA HỆ THỐNG THÔNG TIN**



**LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH HỆ THỐNG THÔNG TIN**

Đề tài

**XÂY DỰNG HỆ THỐNG LƯU TRỮ,
PHÂN LOẠI VÀ TÌM KIẾM HÌNH ẢNH
ĐƯỢC TRÍCH XUẤT TỪ TÀI LIỆU PDF
DỰA TRÊN HỌC SÂU**

Sinh viên: Nguyễn Hà Anh Thư

Mã số: B2103479

Khóa: K47

Cần Thơ, 04/2025

TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG
KHOA HỆ THỐNG THÔNG TIN

LUẬN VĂN TỐT NGHIỆP ĐẠI HỌC
NGÀNH HỆ THỐNG THÔNG TIN

Đề tài

**XÂY DỰNG HỆ THỐNG LƯU TRỮ,
PHÂN LOẠI VÀ TÌM KIẾM HÌNH ẢNH
ĐƯỢC TRÍCH XUẤT TỪ TÀI LIỆU PDF
DỰA TRÊN HỌC SÂU**

Người hướng dẫn
TS. Trần Thanh Điện

Sinh viên: Nguyễn Hà Anh Thư
Mã số: B2103479
Khóa: K47

Cần Thơ, 04/2025

XÁC NHẬN CHỈNH SỬA LUẬN VĂN THEO YÊU CẦU CỦA HỘI ĐỒNG

Tên luận văn (tiếng Việt và tiếng Anh): Xây dựng hệ thống lưu trữ, phân loại và tìm kiếm hình ảnh từ tài liệu PDF dựa trên học sâu (Building a system to store, classify and search images extracted from PDF documents based on deep learning).

Họ tên sinh viên: Nguyễn Hà Anh Thư

MASV: B2103479

Mã lớp: DI2195A2

Đã báo cáo tại hội đồng ngành: Hệ thống thông tin

Ngày báo cáo: 24/04/2025

Luận văn đã được chỉnh sửa theo góp ý của Hội đồng.

Cần Thơ, ngày tháng năm 2025

Giáo viên hướng dẫn

(Ký và ghi họ tên)

Trần Thanh Điện

LỜI CẢM ƠN

Trong suốt quá trình học tập, nghiên cứu và thực hiện đề tài “Xây dựng hệ thống lưu trữ, phân loại và tìm kiếm hình ảnh từ tài liệu PDF dựa trên học sâu.” (Building a system to store, classify and search images extracted from PDF documents based on deep learning), bên cạnh sự nỗ lực không ngừng của bản thân trong việc vận dụng kiến thức đã tiếp thu, tìm tòi và học hỏi các tài liệu liên quan, em đã nhận được sự quan tâm, giúp đỡ và hỗ trợ quý báu từ các thầy cô, gia đình và bạn bè.

Trước tiên, em xin gửi lời cảm ơn chân thành đến thầy Trần Thanh Điện đang giảng dạy khoa Hệ thống thông tin của trường Công nghệ thông tin và truyền thông - Đại học Cần Thơ đã truyền tải kiến thức và hướng dẫn em trong quá trình làm bài.

Em cũng xin chân thành cảm ơn các thầy cô trong khoa đã giảng dạy, cung cấp cho em nền tảng kiến thức vững chắc trong suốt thời gian học tập tại trường. Những bài giảng, kinh nghiệm và sự tận tâm của quý thầy cô chính là hành trang quý báu để em có thể vận dụng vào nghiên cứu và thực tế.

Bài luận văn tốt nghiệp ngành hệ thống thông tin là công sức nhiều ngày qua của em với toàn bộ sự say mê và nhiệt huyết, tuy vậy, do kiến thức hạn chế và không có nhiều kinh nghiệm thực tiễn nên khó tránh khỏi những thiếu sót trong quá trình nghiên cứu và trình bày. Rất kính mong sự góp ý của thầy để bài luận văn tốt nghiệp của em được hoàn thiện hơn.

Xin trân trọng cảm ơn!

Cần Thơ, ngày 24 tháng 04 năm 2025

Sinh viên thực hiện

Nguyễn Hà Anh Thư

TÓM TẮT

Trong những năm gần đây, sự phát triển của trí tuệ nhân tạo (AI) đã mang lại nhiều tiến bộ vượt bậc trong các ứng dụng thị giác máy tính. Một trong những thành tựu nổi bật nhất là sự ra đời của các mô hình mạng nơ-ron tích chập (CNN), trong đó InceptionV3, VGG16 và ResNet50 là ví dụ điển hình. Các mô hình này đã chứng minh hiệu quả trong việc phân loại và nhận dạng hình ảnh nhờ vào kiến trúc đặc trưng và khả năng trích xuất đặc trưng mạnh mẽ từ dữ liệu đầu vào.

Bên cạnh đó, việc đo lường độ tương đồng giữa các hình ảnh cũng là một khía cạnh quan trọng trong thị giác máy tính. Phương pháp cosine similarity (độ tương đồng cosine) là một kỹ thuật phổ biến để xác định mức độ giống nhau giữa hai hình ảnh thông qua các vector đặc trưng.

Mục tiêu của nghiên cứu này là tìm hiểu và ứng dụng các mô hình và giải thuật học sâu cho bài toán liên quan đến thị giác máy tính, cụ thể là phân loại và tính toán độ tương đồng giữa các hình ảnh, sử dụng các mô hình như InceptionV3, VGG16 và ResNet50. Việc phát triển hệ thống này có thể được áp dụng trong nhiều lĩnh vực khác nhau, từ tìm kiếm hình ảnh, nhận dạng đối tượng, đến quản lý dữ liệu hình ảnh.

Từ khóa: Mạng nơ-ron tích chập, Mô hình học sâu, Trích xuất đặc trưng ảnh, Phân loại hình ảnh, Độ tương đồng hình ảnh.

ABSTRACT

In recent years, the development of artificial intelligence (AI) has brought about significant advancements in computer vision applications. One of the most notable achievements is the emergence of convolutional neural network (CNN) models, of which InceptionV3, VGG16 and ResNet50 are good examples. These models have proven effective in image classification and recognition thanks to their signature architecture and robust feature extraction capabilities from input data.

Additionally, measuring the similarity between images is an important aspect of computer vision. The cosine similarity method is a popular technique for determining the similarity between two images through feature vectors.

The objective of this research is to explore and apply deep learning models and algorithms to problems related to computer vision, specifically detecting and calculating the similarity between images, using models such as InceptionV3, VGG16 and ResNet50. The development of this system can be applied in various fields, from image search and object recognition to image data management.

Keywords: Convolutional neural networks, Deep learning models, Image feature extraction, Image classification, Image similarity.

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU	1
1.1. Đặt vấn đề	1
1.2. Các nghiên cứu liên quan.....	2
1.3. Mục tiêu đề tài	2
1.4. Đối tượng và phạm vi đề tài.....	3
1.4.1. Đối tượng nghiên cứu	3
1.4.2. Phạm vi đề tài.....	3
1.5. Nội dung đề tài.....	3
1.6. Những đóng góp chính của đề tài	4
1.7. Bố cục của luận văn	4
1.7.1. Giới thiệu.	4
1.7.2. Mô tả bài toán.	4
1.7.3. Thiết kế và cài đặt giải pháp.	5
1.7.4. Kiểm thử và đánh giá.	5
1.7.5. Kết luận và hướng phát triển.....	5
1.8. Tổng kết chương	5
CHƯƠNG 2. MÔ TẢ BÀI TOÁN	6
2.1. Mô tả chi tiết bài toán	6
2.2. Phân tích đánh giá các giải pháp liên quan đến bài toán	7
2.2.1. AlexNet.	7
2.2.2. VGG	8
2.2.3. GoogleNet – Inception.....	9
2.2.4. ResNet.....	10
2.3. Hướng tiếp cận giải quyết vấn đề, chọn lựa giải pháp của đề tài	12
2.3.1. Hướng tiếp cận thứ 1.	12
2.3.2. Hướng tiếp cận thứ 2 (<i>được lựa chọn</i>).....	13
2.3.3. Tổng kết	13
2.4. Tổng kết chương	13
CHƯƠNG 3. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP	15
3.1. Kiến trúc tổng quát hệ thống.....	15
3.1.1. Kiến trúc huấn luyện mô hình.....	15
3.1.2. Kiến trúc triển khai mô hình phân loại và tìm kiếm ảnh tương đồng.....	19
3.2. Xây dựng các mô hình	21
3.2.1. Mô hình CNN	21
3.2.2. Mô hình InceptionV3.....	24
3.2.3. Mô hình VGG16	25
3.2.4. Mô hình ResNet50	26
3.3. Giải pháp cài đặt	26
3.4. Tổng kết chương	27

CHƯƠNG 4. KIỂM THỬ VÀ ĐÁNH GIÁ.....	28
4.1. Mục tiêu kiểm thử.....	28
4.1.1. Mô tả tập dữ liệu.	28
4.1.2. Các tham số huấn luyện mô hình.	29
4.1.3. Môi trường thực nghiệm.	31
4.1.4. Các độ đo đánh giá thực hiện.....	31
4.1.5. Độ đo tương đồng hình ảnh.	33
4.1.6. Kịch bản kiểm thử.....	33
4.2. Kết quả kiểm thử.....	33
4.2.1. Kết quả kiểm thử kịch bản 1: Đánh giá hiệu suất mô hình phân loại InceptionV3.....	33
4.2.2. Kết quả kiểm thử kịch bản 2: Đánh giá hiệu suất mô hình phân loại VGG16.	37
4.2.3. Kết quả kiểm thử kịch bản 3: Đánh giá hiệu suất mô hình phân loại ResNet50.	41
4.2.4. Kết quả kiểm thử kịch bản 4: Kiểm thử phân loại ảnh và tính độ tương đồng.	45
4.3. Tổng kết chương	46
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	47
5.1. Kết luận.....	47
5.1.1. Kết quả đạt được.	47
5.1.2. Hạn chế.	47
5.2. Hướng phát triển	47
TÀI LIỆU THAM KHẢO.....	49

DANH MỤC HÌNH

Hình 2.1. Mạng AlexNet. [3]	7
Hình 2.2. Mô hình VGG16. [3]	8
Hình 2.3. Mô hình InceptionV1 với các Inception module.[3]	9
Hình 2.4. Mô hình InceptionV3 với các Inception module.[3]	10
Hình 2.5. Mô hình ResNet với 2 khối đặc trưng là khối tích chập (Conv Block) và khối xác định (Identity Block).[3]	11
Hình 2.6. Khối residual cơ bản.[3]	11
Hình 3.1. Quy trình huấn luyện mô hình.	15
Hình 3.2. Quy trình triển khai mô hình phân loại và tìm kiếm ảnh tương đồng	19
Hình 3.3. Cấu trúc đại diện của một mạng nơ ron tích chập.[7].....	21
Hình 3.4. Stride. [7]	22
Hình 3.5. Padding. [7].....	23
Hình 3.6. Filter (kernel)[7].....	23
Hình 3.7. Kiến trúc InceptionV3. [3].....	24
Hình 3.14. Kiến trúc VGG16.....	25
Hình 3.15. Kiến trúc ResNet50.	26
Hình 4.1. Confusion Matrix	32
Hình 4.5. Biểu đồ trực quan hóa hiệu suất của mô hình InceptionV3.....	34
Hình 4.6. Ma trận nhầm lẫn theo tỷ lệ từng lớp của InceptionV3.	35
Hình 4.7. Biểu đồ trực quan hóa hiệu suất của mô hình VGG16.	38
Hình 4.8. Ma trận nhầm lẫn theo tỷ lệ từng lớp của VGG16.	39
Hình 4.9. Biểu đồ trực quan hóa hiệu suất của mô hình ResNet50.	41
Hình 4.10. Ma trận nhầm lẫn theo tỷ lệ từng lớp của ResNet50.	42
Hình 4.11. Giao diện hệ thống.	45
Hình 4.12. Chọn mô hình phân loại.	45
Hình 4.13. Chọn ngưỡng tương đồng.	45
Hình 4.14. Kết quả phân loại.	46

DANH MỤC BẢNG

Bảng 4.1. Số lượng ảnh được gán nhãn.	28
Bảng 4.2. Số lượng ảnh sau khi chia.	29
Bảng 4.3. Tham số huấn luyện mô hình.	29
Bảng 4.4. Các chỉ số đánh giá hiệu suất mô hình InceptionV3.	36
Bảng 4.5. Các chỉ số đánh giá hiệu suất mô hình VGG16.	40
Bảng 4.6. Các chỉ số đánh giá hiệu suất mô hình ResNet50.	43
Bảng 4.7. So sánh các thông số mô hình.	44

DANH MỤC TỪ CHUYÊN NGÀNH

Viết tắt	Giải thích
CNN	Mạng neural tích chập (Convolutional Neural Network)
HOG	Biểu đồ của các gradient định hướng (Histogram of Oriented Gradients)
SIFT	Phép biến đổi đặc trưng bất biến theo tỷ lệ (Scale-Invariant Feature Transform)
SURF	Các tính năng mạnh mẽ được tăng tốc (Speeded Up Robust Features)

CHƯƠNG 1. GIỚI THIỆU

1.1. Đặt vấn đề

Trong bối cảnh công nghệ ngày càng phát triển, lượng tài liệu kỹ thuật số – đặc biệt dưới định dạng PDF – ngày càng gia tăng nhanh chóng trong nhiều lĩnh vực như giáo dục, kỹ thuật, y tế, kinh doanh và quản lý nhà nước. Nhiều tài liệu PDF không chỉ chứa văn bản mà còn có các thành phần hình ảnh như biểu đồ, bản đồ hay mô hình hệ thống. Những hình ảnh này thường mang ý nghĩa đặc thù và cần được tổ chức, phân loại cũng như tìm kiếm một cách hiệu quả.

Tuy nhiên, việc lưu trữ, phân loại và tìm kiếm ảnh từ tài liệu PDF hiện nay chủ yếu vẫn mang tính thủ công, gây tốn thời gian, thiếu chính xác và khó mở rộng trên quy mô lớn. Điều này tạo ra một nhu cầu cấp thiết về một hệ thống có thể tự động phân loại và gợi ý ảnh tương tự, phục vụ cho các bài toán tìm kiếm, phân tích và khai thác dữ liệu hình ảnh hiệu quả hơn.

Với sự phát triển mạnh mẽ của học sâu (Deep Learning), đặc biệt là các kiến trúc mạng nơ-ron tích chập (Convolutional Neural Networks - CNN), nổi bật với khả năng xử lý ảnh và nhận diện các đặc trưng phức tạp trong ảnh. Trong đó, các mô hình nổi bật như GoogleNet – Inception, VGG, ResNet đã chứng minh hiệu quả trong việc phân loại và so sánh hình ảnh, nhờ khả năng học đặc trưng sâu, trích xuất đặc trưng ảnh chính xác và linh hoạt với nhiều kiểu dữ liệu hình ảnh khác nhau.

Tuy nhiên, các mô hình này phần lớn được huấn luyện trên các tập dữ liệu ảnh tự nhiên (như ImageNet), trong đó các hình ảnh chủ yếu là vật thể trong đời sống, phong cảnh hoặc động vật. Điều này dẫn đến việc các mô hình chưa được tối ưu cho ảnh có tính chất đặc thù như ảnh được trích xuất từ PDF – nơi chứa nhiều yếu tố kỹ thuật, có ít màu sắc, độ phân giải không đồng nhất, và thường bao gồm biểu đồ, bản đồ, mô hình hệ thống. Do đó, nếu áp dụng trực tiếp các mô hình này, hiệu quả trong việc phân loại và trích xuất đặc trưng có thể không đạt như mong đợi.

Để giải quyết bài toán trên, nghiên cứu này tiến hành tinh chỉnh (fine-tune) các mô hình học sâu như InceptionV3, VGG16, ResNet50 trên tập ảnh chuyên biệt được trích xuất từ PDF, giúp mô hình thích nghi tốt hơn với loại dữ liệu đặc thù, từ đó cải thiện hiệu quả phân loại và trích xuất đặc trưng ảnh.

Quy trình huấn luyện và tinh chỉnh sẽ bắt đầu bằng việc gán nhãn thủ công cho tập ảnh được trích xuất từ PDF (đã loại bỏ ảnh đen trong quá trình trích xuất) theo nội dung ảnh (như biểu đồ, bản đồ, ảnh chụp thực tế, mô hình hệ thống, ...) sau đó tiến hành chuẩn hóa kích thước ảnh cho phù hợp với đầu vào của mô hình học sâu. Tiếp theo, để làm đa dạng tập huấn luyện, các kỹ thuật tăng cường dữ liệu (data augmentation) sẽ được áp dụng bao gồm các thao tác như xoay ảnh, lật ngang/dọc, thay đổi độ sáng hoặc phóng to/thu nhỏ ảnh. Sau đó, các mô hình CNN sẽ được huấn luyện lại (fine-tune) trên tập dữ liệu này,

trong đó hệ thống có thể tinh chỉnh một phần hoặc toàn bộ các tầng của mô hình tùy thuộc vào độ phức tạp và đặc thù của bài toán.

Sau quá trình huấn luyện, nghiên cứu sẽ tập trung vào việc xây dựng một hệ thống lưu trữ, phân loại và tìm kiếm hình ảnh được trích xuất từ tài liệu PDF. Hệ thống sẽ thực hiện phân loại ảnh theo nhãn nội dung dựa trên mô hình đã tinh chỉnh, sau đó trích xuất đặc trưng ảnh bằng cách biểu diễn ảnh dưới dạng vector. Cuối cùng, hệ thống sử dụng phương pháp đo độ tương đồng ảnh như Cosine Similarity để hỗ trợ quá trình tìm kiếm ảnh tương đồng. Hệ thống kỳ vọng sẽ hỗ trợ người dùng quản lý kho ảnh tài liệu một cách hiệu quả, trực quan và chính xác hơn, từ đó nâng cao hiệu suất làm việc trong môi trường số hóa ngày nay.

1.2. Các nghiên cứu liên quan

Trước đây, các phương pháp như SIFT (Scale-Invariant Feature Transform), SURF (Speeded Up Robust Features), và HOG (Histogram of Oriented Gradients) được sử dụng để trích xuất đặc trưng ảnh. Tuy nhiên, các phương pháp này gặp hạn chế trong việc nhận diện các đặc trưng phức tạp, đặc biệt trong các ảnh có yếu tố kỹ thuật hoặc chứa nhiều chi tiết nhỏ, như ảnh trích từ tài liệu PDF. Những hạn chế đó đã dẫn đến sự phát triển và ứng dụng ngày càng rộng rãi của các mô hình học sâu nhằm thay thế các kỹ thuật truyền thống.

Mạng nơ-ron tích chập (CNN) đã chứng minh được hiệu quả vượt trội trong việc trích xuất đặc trưng ảnh. Các kiến trúc tiên tiến như GoogLeNet, VGG và ResNet đã cải thiện đáng kể độ chính xác và hiệu suất trong các ứng dụng xử lý ảnh, tạo tiền đề cho sự phổ biến và ứng dụng rộng rãi của các mô hình này trong các bài toán nhận diện và phân loại hình ảnh.

Cụ thể, mô hình InceptionV3, phiên bản cải tiến của GoogLeNet, được đánh giá cao nhờ khả năng trích xuất vector đặc trưng của ảnh một cách chính xác. Với kiến trúc hiệu quả và khả năng nhận diện các đặc trưng phức tạp, InceptionV3 đã được sử dụng rộng rãi trong tính toán độ tương đồng ảnh. Bên cạnh đó, VGG16 và ResNet50 cũng cho thấy sự mạnh mẽ trong việc phân loại và trích xuất đặc trưng ảnh, giúp cải thiện độ chính xác trong các nhiệm vụ tìm kiếm ảnh.

Để đo lường mức độ tương đồng, các kỹ thuật như cosine similarity, khoảng cách Euclidean, và khoảng cách Manhattan thường được sử dụng, trong đó cosine similarity là phương pháp hiệu quả khi xử lý các vector đặc trưng lớn.

1.3. Mục tiêu đề tài

Mục tiêu của đề tài “Xây dựng hệ thống lưu trữ, phân loại và tìm kiếm hình ảnh được trích xuất từ tài liệu PDF dựa trên học sâu” là tìm hiểu và ứng dụng các kỹ thuật học sâu như GoogleNet - InceptionV3, VGG16, ResNet50 trong việc phân loại ảnh và xác định độ tương đồng giữa các ảnh.

Quy trình bắt đầu từ việc huấn luyện và tinh chỉnh (fine-tune) các mô hình học sâu trên tập ảnh được trích xuất từ PDF nhằm tối ưu khả năng phân loại và trích xuất đặc trưng phù hợp với ngữ cảnh dữ liệu thực tế. Trước khi huấn luyện, hệ thống thực hiện các bước xử lý gồm: loại bỏ những ảnh đen bị lỗi, gán nhãn thủ công cho ảnh, tiền xử lý dữ liệu để phù hợp với mô hình và áp dụng các kỹ thuật tăng cường dữ liệu (data augmentation) như chuyển vị, thay đổi độ sáng hoặc phóng to/thu nhỏ. Việc tăng cường dữ liệu giúp cải thiện hiệu quả huấn luyện và tăng khả năng tổng quát của mô hình.

Sau khi huấn luyện, hệ thống tiến hành phân loại ảnh bằng cách tiền xử lý ảnh đầu vào cho phù hợp với mô hình. Tiếp theo, hệ thống phân loại ảnh bằng cách dự đoán nhãn cho ảnh, đồng thời trích xuất đặc trưng từ ảnh qua các mô hình học sâu.

Một phần quan trọng của hệ thống là việc áp dụng thuật toán Cosine Similarity để so sánh đặc trưng, từ đó xác định độ 1 tương đồng giữa các ảnh. Nghiên cứu cũng sẽ tiến hành thử nghiệm và đánh giá hiệu quả của mô hình trên một tập dữ liệu cụ thể, đồng thời đề xuất các ứng dụng thực tế như tìm kiếm ảnh tương tự hoặc phát hiện ảnh trùng lặp, góp phần tối ưu hóa quản lý và khai thác dữ liệu hình ảnh.

1.4. Đối tượng và phạm vi đề tài

1.4.1. Đối tượng nghiên cứu

Nghiên cứu chính trong đề tài này là tìm hiểu mô hình học sâu, đặc biệt là mô hình mạng nơ-ron tích chập (CNN) như InceptionV3, VGG16, ResNet50 trong việc phân loại và đo lường độ tương đồng ảnh được trích xuất từ PDF. Các mô hình này sẽ dự đoán nhãn cho ảnh, trích xuất đặc trưng từ ảnh và áp dụng thuật toán Cosine Similarity để tính độ tương đồng giữa các vector đặc trưng của hai hình ảnh.

1.4.2. Phạm vi đề tài

Hệ thống tập trung vào nghiên cứu quy trình phân loại ảnh, tính độ tương đồng ảnh qua các giai đoạn: trích xuất ảnh từ PDF, gán nhãn thủ công cho ảnh để tạo tập dữ liệu cho việc huấn luyện mô hình, tiền xử lý ảnh đầu vào, phân loại ảnh với mô hình học sâu (InceptionV3, VGG16, ResNet50), trích xuất đặc trưng từ ảnh và tính độ tương đồng giữa hai vector đặc trưng của hai hình ảnh.

1.5. Nội dung đề tài

Tìm hiểu về mạng nơ-ron tích chập (CNN) và cấu trúc các mô hình học sâu như InceptionV3, VGG16 và ResNet50, nhằm nắm vững cách các mô hình này hoạt động và áp dụng vào bài toán phân loại ảnh và đo lường độ tương đồng.

Tìm hiểu về Python, sử dụng các thư viện như TensorFlow/Keras, PyMuPDF (fitz), NumPy, SciPy, OS, Tkinter, Pickle, Flask để triển khai quy trình giải quyết bài toán.

Nghiên cứu và áp dụng mô hình InceptionV3, VGG16 và ResNet50 để phân loại, trích xuất đặc trưng từ ảnh, sau đó sử dụng thuật toán Cosine Similarity để đo lường độ tương đồng giữa các vector đặc trưng của các ảnh.

Kiểm thử và đánh giá hiệu quả của hệ thống.

1.6. Những đóng góp chính của đề tài

Đề xuất và triển khai thành công hệ thống phân loại và tìm kiếm ảnh từ tài liệu PDF, bao gồm các bước: trích xuất ảnh, tiền xử lý dữ liệu huấn luyện và ảnh đầu vào, huấn luyện mô hình học sâu, trích xuất đặc trưng, phân loại và tìm kiếm ảnh tương đồng.

Ứng dụng các mô hình học sâu tiêu biểu như InceptionV3, VGG16 và ResNet50 trong bài toán phân loại ảnh thành 5 nhóm: *Photograph*, *Maps*, *System_Model*, *Charts* và *Others*.

Tiến hành huấn luyện lại (fine-tuning) các mô hình trên tập ảnh thực tế trích xuất từ tài liệu PDF nhằm cải thiện hiệu quả phân loại so với mô hình gốc pretrained.

Tích hợp các kỹ thuật hỗ trợ huấn luyện như *EarlyStopping*, *ReduceLROnPlateau* và lưu lại mô hình tốt nhất khi F1-score đạt giá trị tối ưu.

Xây dựng hệ thống phân loại và tìm kiếm ảnh tương đồng dựa trên đặc trưng ảnh, cho phép truy vấn ảnh nhanh chóng theo nội dung tương tự.

Thiết kế giao diện web bằng Flask giúp người dùng dễ dàng tải lên ảnh, lựa chọn mô hình, điều chỉnh ngưỡng similarity và xem kết quả phân loại cũng như tìm kiếm ảnh tương đồng một cách trực quan.

Đánh giá hiệu suất mô hình qua các chỉ số Accuracy, Precision, Recall, F1-score và phân tích ma trận nhầm lẫn (confusion matrix), cho thấy hệ thống đạt hiệu suất cao ở các nhóm ảnh đặc trưng.

1.7. Bố cục của luận văn

Bố cục của bài báo cáo luận văn này gồm 5 phần chính như sau:

1.7.1. Giới thiệu.

Bao gồm các nội dung chi tiết sau:

- Đặt vấn đề.
- Các nghiên cứu liên quan.
- Mục tiêu đề tài.
- Đối tượng và phạm vi đề tài.
- Nội dung đề tài.
- Những đóng góp chính của đề tài.
- Bố cục của luận văn.
- Tổng kết chương.

1.7.2. Mô tả bài toán.

Bao gồm các nội dung chi tiết sau:

- Mô tả chi tiết bài toán.
- Phân tích đánh giá các giải pháp liên quan.
- Hướng tiếp cận giải quyết vấn đề, chọn lựa giải pháp của đề tài.
- Tổng kết chương.

1.7.3. Thiết kế và cài đặt giải pháp.

Bao gồm các nội dung chi tiết sau:

- Kiến trúc tổng quát hệ thống
- Xây dựng các mô hình.
- Giải pháp cài đặt.
- Tổng kết chương.

1.7.4. Kiểm thử và đánh giá.

Bao gồm các nội dung chi tiết sau:

- Mục tiêu kiểm thử.
- Kết quả kiểm thử.
- Tổng kết chương.

1.7.5. Kết luận và hướng phát triển.

Bao gồm các nội dung chi tiết sau:

- Kết luận.
- Hướng phát triển.

1.8. Tổng kết chương

Chương này giới thiệu các phần cơ bản của đề tài, từ việc xác định vấn đề, các nghiên cứu liên quan đến mô hình học sâu, đến các mục tiêu, đối tượng và phạm vi đề tài. Đặc biệt, các mô hình mạng nơ-ron tích chập (CNN) đã được giới thiệu là công cụ mạnh mẽ trong việc phân loại, trích xuất đặc trưng ảnh và đo lường độ tương đồng giữa các ảnh. Mô hình này cải thiện đáng kể hiệu quả so với các phương pháp truyền thống, và mục tiêu của nghiên cứu là ứng dụng nó để xây dựng hệ thống đo lường độ tương đồng ảnh.

CHƯƠNG 2. MÔ TẢ BÀI TOÁN

2.1. Mô tả chi tiết bài toán

Như đã đề cập, đề tài này hướng đến việc xây dựng một hệ thống lưu trữ, phân loại và tìm kiếm hình ảnh được trích xuất từ tài liệu PDF dựa trên học sâu. Hệ thống này sẽ phân loại ảnh đầu vào theo nhãn, sau đó so sánh mức độ tương đồng giữa ảnh đó với tập ảnh cùng nhãn để trả về nhãn phân loại và danh sách các ảnh có mức độ tương đồng cao. Ứng dụng của hệ thống bao gồm tìm kiếm ảnh tương tự trong thương mại điện tử, phát hiện ảnh trùng lặp trong kho lưu trữ, hoặc hỗ trợ phân loại ảnh tự động.

Để xây dựng hệ thống, bài toán được chia thành hai giai đoạn chính:

Giai đoạn huấn luyện:

- **Trích xuất ảnh và gán nhãn thủ công:** Ảnh sẽ được trích xuất từ các tài liệu PDF sử dụng thư viện PyMuPDF (fitz). Các ảnh không hợp lệ như ảnh toàn nền đen (thường do công thức toán học hoặc hình vẽ tay bằng thanh công cụ bị lỗi khi trích xuất) sẽ bị loại bỏ, ảnh còn lại sẽ được gán nhãn thủ công để tạo tập dữ liệu huấn luyện.

- **Tiền xử lý và tăng cường dữ liệu:** Ảnh được chuẩn hóa về kích thước, chuyển đổi định dạng phù hợp với đầu vào của mô hình, và áp dụng các kỹ thuật tăng cường dữ liệu như xoay ảnh, lật ảnh, điều chỉnh độ sáng, thu phóng để nâng cao tính đa dạng cho tập huấn luyện.

- **Huấn luyện và tinh chỉnh các mô hình học sâu:** Các mô hình CNN như InceptionV3, VGG16, ResNet50 được fine-tune trên tập dữ liệu ảnh đã xử lý. Tùy vào mức độ phức tạp của bài toán, một phần hoặc toàn bộ các tầng của mô hình sẽ được điều chỉnh. Sau quá trình huấn luyện, mô hình được lưu lại để sử dụng trong giai đoạn triển khai phân loại và tìm kiếm.

- **Trích xuất đặc trưng ảnh từ tập dữ liệu:** Từ các ảnh trong tập dữ liệu, hệ thống sử dụng mô hình đã huấn luyện để trích xuất vector đặc trưng (feature vector) đại diện cho nội dung ảnh. Các vector này sẽ được lưu trữ riêng biệt bằng định dạng .pkl thông qua thư viện pickle, tạo thành cơ sở dữ liệu đặc trưng phục vụ cho việc tính toán độ tương đồng ảnh trong quá trình tìm kiếm sau này. Việc lưu vector đặc trưng dưới dạng file .pkl giúp tăng tốc quá trình tìm kiếm và tiết kiệm tài nguyên khi hệ thống không cần trích xuất lại đặc trưng từ ảnh gốc.

Giai đoạn triển khai phân loại và tìm kiếm:

- **Tiền xử lý ảnh đầu vào:** Ảnh mới được đưa vào được chuẩn hóa ảnh giống với tập huấn luyện nhằm đảm bảo tính nhất quán và hiệu quả trong quá trình xử lý.

- **Phân loại và trích xuất đặc trưng:** Ảnh được phân loại theo nhãn dựa trên các mô hình học sâu đã huấn luyện trước đó. Sau đó, ảnh được trích xuất đặc trưng được biểu diễn dưới dạng các vector đặc trưng đại diện cho nội dung ảnh.

- **Tính toán độ tương đồng:** Dựa trên các vector đặc trưng, hệ thống sử dụng kỹ thuật Cosine Similarity, một phương pháp hiệu quả trong việc so sánh các vector trong không gian đa chiều, để tính toán độ tương đồng giữa vector đặc trưng của ảnh đầu vào và các vector trong file .pkl, giới hạn trong cùng nhóm nhãn để tăng độ chính xác.


- **Sắp xếp và trả kết quả:** Hệ thống trả về ảnh đầu vào, nhãn dự đoán, xác suất dự đoán và bảng các ảnh có độ tương đồng cao với ảnh đầu vào, được sắp xếp theo mức độ tương đồng giảm dần. Mỗi ảnh trong danh sách này sẽ được hiển thị kèm theo tỷ lệ phần trăm tương đồng, giúp người dùng dễ dàng đánh giá và lựa chọn các ảnh phù hợp.

2.2. Phân tích đánh giá các giải pháp liên quan đến bài toán

Trong lĩnh vực xử lý ảnh, các mô hình học sâu, đặc biệt là các kiến trúc mạng nơ-ron tích chập (CNN) đã đạt được những thành tựu vượt bậc trong việc nhận diện và phân loại hình ảnh. Một số mô hình CNN tiêu biểu có thể kể đến là AlexNet, VGG, GoogleNet - Inception, ResNet. Mỗi mô hình có những ưu điểm riêng biệt trong việc trích xuất đặc trưng và xử lý ảnh.

2.2.1. AlexNet.

Mạng AlexNet là một trong những mạng nơ-ron tích chập tiêu biểu, được giới thiệu vào năm 2012 bởi Alex Krizhevsky, Ilya Sutskever và Geoffrey Hinton. Mạng được đặt theo tên của Alex Krizhevsky, tác giả thứ nhất của bài báo “**Imagenet classification with deep convolutional neural networks.**”. Mạng AlexNet bao gồm 8 tầng mạng nơ-ron tích chập Hình 2.1, đã chiến thắng cuộc thi **ILSVRC 2012 (ImageNet Large Scale Visual Recognition Challenge** năm 2012) với cách biệt không tưởng [1].



Hình 2.1. Mạng AlexNet. [3]

- Ưu điểm [2]:

+ Sử dụng nhiều tầng tích chập hơn với không gian tham số lớn hơn để khớp tập dữ liệu ImageNet với kích thước lớn.

+ Thay thế hàm kích hoạt Sigmoid bằng ReLU, đây là cải tiến đáng chú ý vì hàm sigmoid có độ phức tạp tính toán rất lớn so với hàm ReLU, giúp đẩy nhanh quá trình huấn luyện.

- + Sử dụng Max Pooling, Max Pooling được đánh giá hiệu quả hơn trong việc tính toán đạo hàm, cũng như giảm overfitting so với Average Pooling, ngoài ra nó vẫn mang ý nghĩa downsampling, trích rút các thông tin gọn hơn.

- + Tận dụng được sức mạnh tính toán của GPU.

- Nhược điểm:


- + Nhiều công đoạn code phức tạp.

- + Chưa có một mẫu chung để lựa chọn các tham số cho các lớp như kernel size, stride, padding, ...

Mặc dù hiện tại không còn được sử dụng phổ biến do sự ra đời của các kiến trúc tiên tiến hơn, AlexNet vẫn là nền tảng giúp định hình các kiến trúc CNN hiện đại và có giá trị tham khảo trong các nghiên cứu về học sâu ứng dụng trong xử lý ảnh.

2.2.2. VGG

VGG là một mạng nơ-ron tích chập tiêu biểu, được giới thiệu vào năm 2014 bởi nhóm nghiên cứu từ Visual Geometry Group (VGG) tại đại học Oxford trong bài báo “**Very Deep Convolutional Networks for Large-Scale Image Recognition.**”. Có nhiều phiên bản của VGG được phát triển, trong đó VGG16 là cấu trúc phổ biến nhất với 13 layers tích chập 2 chiều và 3 layers fully connected Hình 2.2 [3].



Hình 2.2. Mô hình VGG16. [3]

- Ưu điểm [3]:

- + Lần đầu tiên xuất hiện khái niệm về khối tích chập (block). Đây là những kiến trúc gồm một tập hợp các layers CNN được lặp lại giống nhau. Kiến trúc khối đã khởi nguồn cho một dạng kiến trúc hình mẫu rất thường gặp ở các mạng CNN kể từ đó.

- + Cũng kế thừa lại hàm activation ReLU ở AlexNet.

- + Là kiến trúc đầu tiên thay đổi thứ tự của các block khi xếp nhiều layers CNN + max pooling thay vì xen kẽ chỉ một layer CNN + max pooling.

- + Chỉ sử dụng các bộ lọc kích thước nhỏ 3x3 thay vì nhiều kích thước bộ lọc như AlexNet. Kích thước bộ lọc nhỏ sẽ giúp giảm số lượng tham số cho mô hình và mang lại hiệu quả tính toán hơn.

VGG đặc biệt phù hợp trong các bài toán yêu cầu mô hình có tính ổn định cao, dễ triển khai và tối ưu. Nhược điểm chính là kích thước mô hình lớn và thời gian huấn luyện

dài, tuy nhiên trong các bài toán phân loại hình ảnh tài liệu, VGG vẫn thể hiện hiệu suất ổn định.


2.2.3. GoogleNet – Inception.

Inception là một dòng kiến trúc CNN do nhóm nghiên cứu của Google đề xuất, với các phiên bản tiêu biểu như InceptionV1 và InceptionV3. InceptionV1 giúp giảm thiểu số lượng tham số thông qua các phép tích chập 1×1 và các module xử lý song song, trong khi InceptionV3 tiếp tục cải tiến với kỹ thuật factorization và batch normalization giúp tăng tốc huấn luyện và giảm hiện tượng quá khớp.

2.2.3.1. InceptionV1.

Mạng Inception-V1 là một mạng nơ-ron tích chập tiêu biểu được giới thiệu bởi nhóm nghiên cứu của Google vào năm 2014 trong bài báo “**Going deeper with convolutions.**”, đã dành chiến thắng ở cuộc thi **ILSVRC 2014 (ImageNet Large Scale Visual Recognition Challenge** năm 2014) [4].

Kiến trúc này đã giải quyết một câu hỏi lớn trong mạng CNN đó là sử dụng *kernel_size* với kích thước bao nhiêu thì hợp lý. Các kiến trúc mạng nơ-ron trước đó đều sử dụng các bộ lọc với đa dạng các kích thước 11×11 , 5×5 , 3×3 cho tới nhỏ nhất là 1×1 [3].



Hình 2.3. Mô hình InceptionV1 với các Inception module.[3]


- Ưu điểm:

+ Toàn bộ mạng bao gồm 22 Layers Hình 2.3, lớn hơn gần gấp đôi so với VGG-16.

+ Áp dụng tích chập 1×1 giúp tiết kiệm số lượng tham số xuống chỉ còn 5 triệu, ít hơn gần 27 lần so với VGG-16.

2.2.3.2. InceptionV3

Inception-V3 là kế thừa của Inception-V1 bao gồm 24 triệu tham số Hình 2.4. Toàn bộ các layer tích chập của Inception-V3 được theo sau bởi một layer batch normalization và một ReLU activation. Batch normalization là kỹ thuật chuẩn hóa đầu vào theo từng minibatch tại mỗi layer theo phân phối chuẩn hóa $N(0,1)$, giúp cho quá trình huấn luyện thuật toán nhanh hơn [3].



Hình 2.4. Mô hình InceptionV3 với các Inception module.[3]

- Ưu điểm:


- + Giải quyết được vấn đề thắt cổ chai (representational bottlenecks).
- + Có một cách tính toán hiệu quả hơn nhờ sử dụng phương pháp nhân tố (factorisation methods).

2.2.4. ResNet

Mạng ResNet (Residual Network) là một mạng nơ-ron tích chập nổi bật, được giới thiệu bởi nhóm nghiên cứu từ Microsoft Research (MSRA) gồm Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun vào năm 2015 trong bài báo “**Deep Residual**

Learning for Image Recognition.”, đã dành chiến thắng ở cuộc thi **ILSVRC 2015 (ImageNet Large Scale Visual Recognition Challenge** năm 2015) [5].

ResNet (Hình 2.5) có khối tích chập (Convolutional Block, chính là Conv block) sử dụng bộ lọc kích thước 3×3 giống với của InceptionNet. Khối tích chập bao gồm 2 nhánh tích chập trong đó một nhánh áp dụng tích chập 1×1 trước khi cộng trực tiếp vào nhánh còn lại. Khối xác định (Identity block) thì không áp dụng tích chập 1×1 mà cộng trực tiếp giá trị của nhánh đó vào nhánh còn lại.




Hình 2.5. Mô hình ResNet với 2 khối đặc trưng là khối tích chập (Conv Block) và khối xác định (Identity Block).[3]

- Ưu điểm:

+ Là một mạng rất sâu khi có số lượng layer lên tới 152 nhưng nhờ áp dụng những kỹ thuật đặc biệt nên kích thước của ResNet50 chỉ khoảng 26 triệu tham số.

+ Sử dụng skip connections hoặc residual connections (Hình 2.6) giữa các lớp để giải quyết vấn đề suy giảm độ chính xác khi mô hình trở nên sâu hơn.



Hình 2.6. Khối residual cơ bản.[3]

ResNet nổi bật nhờ khả năng mở rộng độ sâu của mạng mà không gặp phải vấn đề suy giảm hiệu suất, điều này rất hữu ích trong các bài toán phức tạp đòi hỏi mô hình học được nhiều cấp độ đặc trưng. Với kích thước mô hình vừa phải (ví dụ: ResNet50 ~26 triệu tham số), ResNet là một lựa chọn cân bằng giữa hiệu năng và chi phí tính toán, phù hợp để áp dụng trong hệ thống mà đề tài đề xuất.

Các mô hình CNN kinh điển như **AlexNet**, **VGG**, **Inception**, **ResNet** đều đã góp phần định hình nên các kiến trúc học sâu hiện đại, mỗi mô hình mang lại những cải tiến riêng biệt về mặt cấu trúc và hiệu quả huấn luyện.

- **AlexNet** là tiền đề mở đường, chứng minh tính khả thi và sức mạnh của deep learning trong nhận dạng ảnh.

- **VGG** đơn giản nhưng hiệu quả, rất phù hợp cho các tác vụ yêu cầu mô hình ổn định, dễ triển khai.

- **Inception** chú trọng vào việc tối ưu số lượng tham số và hiệu suất xử lý nhờ thiết kế module đa nhánh, sử dụng tích chập 1x1, factorization và batch normalization.

- **ResNet** nổi bật với cơ chế **skip connections**, giải quyết được vấn đề suy giảm độ chính xác khi mạng trở nên sâu, giúp mô hình học hiệu quả hơn với độ sâu lớn.

Trong phạm vi đề tài này, ba mô hình **VGG16**, **InceptionV3** và **ResNet50** được lựa chọn triển khai, huấn luyện và đánh giá nhằm so sánh hiệu quả giữa các kiến trúc CNN hiện đại. Mỗi mô hình sẽ được fine-tune trên tập dữ liệu ảnh được trích xuất từ tài liệu PDF, nhằm đánh giá khả năng phân loại và truy xuất ảnh tương đồng trong bối cảnh thực tế. Việc so sánh nhiều mô hình giúp lựa chọn được kiến trúc phù hợp nhất, cân bằng giữa độ chính xác, chi phí tính toán và khả năng mở rộng hệ thống.

2.3. Hướng tiếp cận giải quyết vấn đề, chọn lựa giải pháp của đề tài

Để giải quyết bài toán phân loại và tính toán độ tương đồng giữa các ảnh, luận văn đề xuất hai hướng tiếp cận chính: sử dụng các kỹ thuật xử lý ảnh truyền thống và sử dụng các mô hình mạng nơ-ron tích chập.

2.3.1. Hướng tiếp cận thứ 1.

Sử dụng các kỹ thuật xử lý ảnh truyền thống.

Trong hướng tiếp cận này, bài toán có thể được giải quyết thông qua việc sử dụng các kỹ thuật xử lý ảnh truyền thống như HOG (Histogram of Oriented Gradients) để trích xuất đặc trưng của ảnh.

Trong xử lý ảnh, thuật toán HOG là một trong những bộ mô tả đặc trưng mạnh giúp mã hóa hình ảnh thành một vector đặc trưng với số chiều đủ lớn để có thể phân loại tốt các bức ảnh. Trong một số trường hợp phân loại ảnh, khi bộ dữ liệu có kích thước nhỏ thì những mạng nơ-ron lớn như CNN có thể hoạt động không chính xác do tập ảnh huấn luyện không đủ bao quát các khả năng. Khi đó việc áp dụng những phương pháp cổ điển để trích lọc đặc trưng như HOG lại mang lại những kết quả bất ngờ mà tốn ít tài nguyên và chi phí tính toán.

Qua đó chúng ta thấy được HOG mặc dù là phương pháp cũ nhưng vẫn rất hiệu quả trong nhiều bài toán. Tùy từng tình huống mà chúng ta có thể sử dụng thuật toán HOG chứ

không nhất thiết phải áp dụng một mô hình deep learning với hàng triệu tham số thì mới mang lại độ chính xác cao [6].

2.3.2. Hướng tiếp cận thứ 2 (được lựa chọn)

Sử dụng các mô hình mạng nơ-ron tích chập.

Trong hướng tiếp cận này, các mô hình học sâu, đặc biệt là các mô hình CNN tiên tiến (như InceptionV3, VGG16, ResNet50) được sử dụng để phân loại và trích xuất các đặc trưng từ ảnh. Các mô hình CNN này có khả năng trích xuất các đặc trưng chi tiết và phức tạp từ ảnh, giúp nâng cao hiệu quả trong việc nhận dạng và so sánh nội dung ảnh.

Trước tiên, ảnh đầu vào sẽ được phân loại vào một trong các nhóm bằng mô hình đã huấn luyện. Việc phân loại này giúp thu hẹp phạm vi tìm kiếm, tăng tốc độ và độ chính xác trong quá trình so sánh ảnh.

Sau khi xác định được nhóm ảnh, hệ thống sẽ sử dụng mô hình CNN phù hợp để trích xuất vector đặc trưng. Với việc áp dụng các mô hình CNN tiên tiến, ảnh đầu vào được chuyển thành các vector đặc trưng chất lượng cao, từ đó cải thiện đáng kể độ chính xác khi so sánh độ tương đồng.

Cuối cùng, các vector đặc trưng này sẽ được so sánh bằng Cosine Similarity để đánh giá mức độ tương đồng giữa ảnh đầu vào và các ảnh trong cơ sở dữ liệu. Hướng tiếp cận này đảm bảo được độ chính xác cao và khả năng nhận diện tốt trong nhiều loại ảnh khác nhau.

2.3.3. Tổng kết

Sau khi phân tích và so sánh hai hướng tiếp cận, luận văn lựa chọn **hướng tiếp cận thứ hai – sử dụng các mô hình mạng nơ-ron tích chập (CNN)**. Lý do là vì các mô hình học sâu, đặc biệt là các kiến trúc CNN hiện đại như InceptionV3, VGG16 và ResNet50, có khả năng trích xuất đặc trưng ảnh mạnh mẽ và tổng quát hơn so với các phương pháp truyền thống.

Mặc dù các kỹ thuật như HOG có ưu điểm về tính đơn giản và chi phí tính toán thấp, nhưng chúng thường không đủ khả năng nhận diện tốt trong những tập dữ liệu lớn, phức tạp và đa dạng như ảnh trích xuất từ tài liệu PDF. Trong khi đó, mô hình CNN không chỉ cho phép phân loại chính xác mà còn hỗ trợ hiệu quả trong việc tìm kiếm ảnh tương đồng thông qua vector đặc trưng.

Việc chọn hướng tiếp cận này không chỉ phù hợp với xu thế nghiên cứu hiện đại mà còn đáp ứng tốt yêu cầu thực tiễn về độ chính xác, khả năng mở rộng và tính tự động hóa trong hệ thống phân loại và tìm kiếm ảnh.

2.4. Tổng kết chương

Chương này đã mô tả chi tiết bài toán xây dựng một hệ thống lưu trữ, phân loại và tìm kiếm hình ảnh được trích xuất từ tài liệu PDF dựa trên học sâu. Hệ thống này sử dụng

các mô hình học sâu hiện đại để phân loại ảnh và tìm kiếm ảnh tương đồng dựa trên các vector đặc trưng được trích xuất từ mô hình CNN. Các mô hình CNN như AlexNet, VGG, GoogleNet (Inception), và ResNet đã được phân tích đánh giá.


Đồng thời, chương này cũng đưa ra hai hướng tiếp cận chính để giải quyết bài toán. Việc lựa chọn hướng tiếp cận thứ hai, **sử dụng các mô hình mạng nơ-ron tích chập (CNN)** để phân loại và trích xuất đặc trưng, kết hợp với Cosine Similarity, đã được chứng minh là một giải pháp hiệu quả hơn nhờ khả năng trích xuất đặc trưng ảnh mạnh mẽ và khả năng tổng quát hóa tốt. Các mô hình CNN cho phép xử lý ảnh từ các tài liệu PDF có độ phức tạp cao, đồng thời đảm bảo tính chính xác và hiệu quả trong việc tìm kiếm ảnh tương đồng, đáp ứng tốt các yêu cầu thực tế của hệ thống. Hướng tiếp cận này là cơ sở cho các bước phát triển hệ thống trong các chương tiếp theo.

CHƯƠNG 3. THIẾT KẾ VÀ CÀI ĐẶT GIẢI PHÁP

3.1. Kiến trúc tổng quát hệ thống

Hệ thống xây dựng nhằm lưu trữ, phân loại và tìm kiếm hình ảnh được trích xuất từ tài liệu PDF, dựa trên các mô hình học sâu như InceptionV3, VGG16, ResNet50 nhằm đảm bảo độ chính xác và hiệu quả cao trong việc xử lý ảnh. Quá trình thực hiện gồm 2 quy trình chính: Huấn luyện, tinh chỉnh mô hình để phân loại, trích xuất đặc trưng ảnh và triển khai mô hình nhằm phân loại ảnh mới, đồng thời tìm kiếm các ảnh tương đồng trong tập dữ liệu đã lưu.

3.1.1. Kiến trúc huấn luyện mô hình.



Hình 3.1. Quy trình huấn luyện mô hình.

Quy trình huấn luyện mô hình Hình 3.1 bắt đầu bằng việc trích xuất ảnh từ PDF để lấy được dữ liệu ảnh chuẩn bị cho việc huấn luyện mô hình. Sử dụng thư viện PyMuPDF (fitz) để thực hiện trích xuất ảnh từ thư mục chứa các tệp PDF được chọn. Mỗi tệp PDF sẽ được duyệt qua từng trang để trích xuất toàn bộ hình ảnh nhúng bên trong. Tuy nhiên, trong thực tế, nhiều tài liệu PDF chứa các hình vẽ tay, sơ đồ từ Word hoặc các công thức toán học được chèn bằng công cụ vẽ. Khi trích xuất, những hình ảnh này thường bị lỗi và thể hiện dưới dạng các ảnh đen (ảnh không chứa thông tin hữu ích). Vì vậy, sau bước trích xuất, hệ thống sẽ lọc và loại bỏ các ảnh đen để đảm bảo chất lượng dữ liệu đầu vào. Sau đó, các ảnh hợp lệ sẽ được lưu vào một thư mục riêng, sau đó tiến hành gán nhãn thủ công để xây dựng tập dữ liệu huấn luyện cho mô hình học sâu ở các bước tiếp theo.

Sau khi gán nhãn thủ công cho các ảnh đã trích xuất xong, tập ảnh sẽ được chia thành 3 tập nhỏ để tiến hành huấn luyện mô hình theo tỷ lệ:

- **Tập huấn luyện (train):** chiếm **80%** tổng số ảnh, được sử dụng để huấn luyện mô hình học sâu.
- **Tập kiểm tra (validation - val):** chiếm **10%**, được sử dụng để theo dõi và điều chỉnh quá trình huấn luyện nhằm tránh hiện tượng quá khớp (overfitting).
- **Tập kiểm thử (test):** chiếm **10%**, dùng để đánh giá hiệu suất cuối cùng của mô hình sau khi huấn luyện.

Sau khi tập ảnh được chia, hệ thống tiến hành chuẩn bị dữ liệu huấn luyện từ tập train và validation. Các bước chuẩn bị này bao gồm:

- **Thay đổi kích thước ảnh:** Tất cả ảnh được resize về kích thước chuẩn theo yêu cầu của mô hình, ví dụ: 224x224 cho VGG16, ResNet50 và 299x299 cho InceptionV3. Việc thống nhất kích thước giúp đảm bảo tensor đầu vào có định dạng nhất quán.
- **Chuẩn hóa giá trị điểm ảnh:** Sử dụng hàm *preprocess_input* tương ứng với từng mô hình (InceptionV3, VGG16, ResNet50...) để chuẩn hóa ảnh về định dạng phù hợp với chuẩn huấn luyện gốc. Việc sử dụng *preprocess_input* giúp đồng nhất dữ liệu đầu vào với dữ liệu gốc mà mô hình đã được huấn luyện trước (pre-trained), từ đó giúp mô hình hoạt động ổn định và đạt hiệu quả cao hơn trong cả huấn luyện lẫn suy luận.

- **Tăng cường dữ liệu (Data Augmentation):** là một kỹ thuật xử lý dữ liệu trong lĩnh vực thị giác máy tính và học sâu, giúp tạo ra các phiên bản thay đổi của hình ảnh gốc bằng cách áp dụng các phép biến đổi như xoay, lật, phóng to/thu nhỏ, dịch chuyển nhẹ, thay đổi độ sáng... Mục đích là làm tăng tính đa dạng cho tập huấn luyện, giúp mô hình học được các biến thể trong thực tế, cải thiện khả năng tổng quát hóa, từ đó tăng hiệu suất mô hình. Các phương pháp tăng cường dữ liệu được sử dụng trong nghiên cứu này bao gồm phóng to/thu nhỏ, thay đổi độ sáng và dịch chuyển ảnh để làm phong phú tập huấn luyện.

Sau khi chuẩn bị dữ liệu huấn luyện, hệ thống tiến hành xây dựng mô hình học sâu. Trước tiên, mô hình đã được huấn luyện trước (pre-trained model) trên tập dữ liệu lớn như

ImageNet được tải về. Tiếp theo, đóng băng các lớp (Freezing layers) – tức là không cập nhật trọng số của các lớp này trong quá trình huấn luyện – tùy theo mô hình huấn luyện. Việc đóng băng này giúp giữ nguyên các đặc trưng tổng quát đã học trước đó từ tập dữ liệu lớn (như ImageNet), đồng thời cho phép huấn luyện các lớp phía sau để mô hình thích nghi với bài toán phân loại ảnh cụ thể của đề tài. Sau đó, hệ thống tiến hành xây dựng phần đầu ra mới (custom classifier) để phù hợp với bài toán phân loại ảnh cụ thể của đề tài. Cụ thể, đầu ra của mô hình gốc được kết nối với một lớp GlobalAveragePooling2D, giúp giảm số lượng tham số và tránh overfitting. Sau đó, thêm một lớp Dense với 512 nút và hàm kích hoạt ReLU nhằm học các đặc trưng phi tuyến sâu hơn. Cuối cùng, sử dụng một lớp Dense với 5 nút đầu ra và hàm kích hoạt softmax, tương ứng với 5 nhãn phân loại trong đề tài.

Sau khi hoàn tất việc xây dựng mô hình học sâu – bao gồm tải mô hình tiền huấn luyện, đóng băng các lớp, và thêm các lớp đầu ra phù hợp với bài toán phân loại ảnh – mô hình cần được **biên dịch (compile)** trước khi huấn luyện. Trong bước này, ta chọn:

- **Hàm mất mát (loss function):** sử dụng *categorical_crossentropy* do bài toán là phân loại nhiều lớp.

- **Bộ tối ưu (optimizer):** thường dùng *Adam* vì khả năng hội tụ nhanh và hiệu quả với mạng sâu.

- **Chỉ số đánh giá (metrics):** dùng *accuracy* để theo dõi độ chính xác trong quá trình huấn luyện.

Sau khi mô hình được biên dịch, hệ thống bắt đầu quá trình huấn luyện mô hình học sâu trên tập dữ liệu đã được chuẩn bị từ trước (gồm tập huấn luyện và kiểm tra). Trong quá trình huấn luyện, mô hình sẽ học cách phân biệt giữa các lớp ảnh thông qua việc điều chỉnh trọng số dựa trên hàm mất mát. Để tối ưu quá trình huấn luyện, hệ thống sử dụng các kỹ thuật hỗ trợ như:

EarlyStopping (Dừng sớm)¹: Giám sát hàm mất mát trên tập kiểm tra. Nếu sau một số epoch nhất định mà độ chính xác không cải thiện, quá trình huấn luyện sẽ tự động dừng lại, nhằm tránh hiện tượng quá khớp (overfitting). Điều này giúp giảm lãng phí tài nguyên và cải thiện khả năng tổng quát của mô hình. Đặc biệt, khi kết hợp với tham số *restore_best_weights=True*, mô hình sẽ được khôi phục lại trọng số tốt nhất từ epoch có hiệu suất cao nhất, thay vì lưu lại trọng số từ epoch cuối cùng.

ReduceLROnPlateau (Giảm tốc độ học)²: Nếu trong quá trình huấn luyện độ chính xác không cải thiện trong vài epoch, hệ thống sẽ tự động giảm tốc độ học (learning rate) để mô hình có thể tiếp tục tối ưu hóa tốt hơn tại các điểm gần cực tiểu cục bộ.

¹ https://keras.io/api/callbacks/early_stopping/

² https://pytorch.org/docs/stable/generated/torch.optim.lr_scheduler.ReduceLROnPlateau.html

Sau khi huấn luyện xong, mô hình sẽ được đánh giá trên tập kiểm thử (test set). Tập kiểm thử này không được sử dụng trong quá trình huấn luyện, vì vậy nó giúp kiểm tra khả năng tổng quát của mô hình đối với dữ liệu chưa từng thấy. Các chỉ số như độ chính xác (accuracy), F1-score, Precision và Recall sẽ được tính toán để đánh giá hiệu suất của mô hình.

Nếu mô hình không đạt được kết quả mong muốn (ví dụ: F1-score không đạt ngưỡng yêu cầu, chẳng hạn 0.75), hệ thống sẽ quay lại và thực hiện điều chỉnh tham số huấn luyện. Các tham số có thể điều chỉnh bao gồm:

Số lượng epoch: Điều chỉnh số lượng epoch để mô hình có thể huấn luyện đủ lâu mà không bị overfitting.

Learning rate: Thử nghiệm với các giá trị khác nhau của tốc độ học để mô hình học nhanh hơn hoặc chậm hơn, tùy thuộc vào sự hội tụ.

Batch size: Điều chỉnh kích thước batch để có thể đạt được hiệu quả tối ưu hơn.

Ngưỡng **F1-score = 0.75** được lựa chọn dựa trên mục tiêu đảm bảo mô hình có khả năng **cân bằng giữa độ chính xác (precision) và độ bao phủ (recall)** ở mức tương đối cao. Trong nhiều bài toán phân loại, đặc biệt là với dữ liệu mất cân bằng, F1-score là thước đo phù hợp để đánh giá tổng thể chất lượng mô hình. Ngưỡng 0.75 thể hiện mức hiệu suất tốt, phù hợp với yêu cầu ứng dụng thực tế và đảm bảo rằng mô hình không chỉ đúng mà còn ổn định khi phân loại các lớp nhỏ.³

Khi mô hình đạt được F1-score trên 0.75 hoặc các chỉ số đánh giá khác đạt yêu cầu, mô hình sẽ được lưu lại để sử dụng cho các bước suy luận hoặc ứng dụng trong tương lai. Việc lưu mô hình giúp tránh việc phải huấn luyện lại từ đầu, tiết kiệm thời gian và tài nguyên. Mô hình được lưu dưới dạng tệp .h5 hoặc một định dạng khác phù hợp, chứa trọng số đã học và cấu trúc của mô hình.

Để quá trình tính toán độ tương đồng ảnh diễn ra nhanh chóng và hiệu quả, hệ thống sẽ sử dụng mô hình học sâu đã huấn luyện và lưu trước đó để trích xuất đặc trưng cho toàn bộ tập ảnh huấn luyện. Việc trích xuất đặc trưng giúp chuyển đổi mỗi ảnh thành một vector số có kích thước cố định, đại diện cho các đặc trưng ngữ nghĩa sâu của ảnh đó trong không gian đặc trưng do mô hình học sâu học được.

Các bước thực hiện bao gồm:

- Tải mô hình đã lưu đạt hiệu suất tốt nhất sau huấn luyện.
- Lớp đầu ra softmax của mô hình sẽ được loại bỏ, chỉ giữ lại phần mô hình dùng để trích xuất đặc trưng. Cụ thể là lấy đầu ra từ lớp *GlobalAveragePooling2D*.
- Mỗi ảnh trong tập dữ liệu sẽ được xử lý qua các bước:

³ <https://encord.com/blog/f1-score-in-machine-learning/>


- + Resize về kích thước chuẩn phù hợp với mô hình.
- + Chuẩn hóa điểm ảnh thông qua *preprocess_input* tương ứng với mô hình.
- + Đưa ảnh qua mô hình để lấy vector đặc trưng.

Sau khi trích xuất xong đặc trưng ảnh bằng mô hình học sâu (ví dụ InceptionV3, VGG16 hoặc ResNet50), tất cả các vector đặc trưng kèm theo nhãn tương ứng sẽ được lưu trữ vào file, thường ở định dạng .pkl (Pickle) hoặc .npy (NumPy). Việc lưu này không chỉ giúp tái sử dụng dữ liệu một cách dễ dàng trong các bước xử lý sau, mà còn giúp tăng tốc đáng kể quá trình truy vấn và tính toán độ tương đồng ảnh sau này.

Sau khi lưu mô hình và vector đặc trưng, quy trình huấn luyện và đánh giá hoàn tất. Mô hình có thể được sử dụng trong các ứng dụng thực tế hoặc triển khai cho các nhiệm vụ nhận diện ảnh hoặc phân loại ảnh.

Thông qua quy trình này, mô hình học sâu được huấn luyện, tối ưu hóa và đánh giá để đảm bảo hiệu suất cao và khả năng tổng quát tốt đối với các dữ liệu chưa từng thấy, đồng thời lưu trữ các kết quả quan trọng để phục vụ cho các bước sử dụng trong tương lai.

3.1.2. Kiến trúc triển khai mô hình phân loại và tìm kiếm ảnh tương đồng.



Hình 3.2. Quy trình triển khai mô hình phân loại và tìm kiếm ảnh tương đồng

Sau khi mô hình học sâu đã được huấn luyện và lưu lại, ứng dụng web sử dụng Flask sẽ được triển khai để phục vụ việc phân loại và tìm kiếm ảnh tương đồng. Quy trình này được mô tả ở Hình 3.2 và bắt đầu từ việc khởi tạo ứng dụng Flask và tải mô hình đã huấn luyện như InceptionV3, VGG16, ResNet50.

Khi người dùng truy cập trang web và tải ảnh lên, họ sẽ được yêu cầu chọn một trong các mô hình học sâu đã được huấn luyện sẵn, như VGG16, ResNet50, và InceptionV3. Mỗi mô hình có cấu trúc và khả năng nhận diện đặc trưng ảnh khác nhau, do đó, việc lựa chọn mô hình phù hợp giúp tối ưu hóa độ chính xác cho từng loại ảnh hoặc bài toán phân loại.

Sau đó, người dùng cũng có thể thiết lập ngưỡng tương đồng (threshold) để xác định mức độ tương đồng tối thiểu giữa ảnh đầu vào và các ảnh trong tập ảnh huấn luyện. Ngưỡng này đóng vai trò quan trọng trong việc lọc ra các ảnh có độ tương đồng cao, giúp giảm thiểu số lượng ảnh không liên quan mà hệ thống trả về. Ví dụ, nếu ngưỡng được đặt là 0.9, chỉ những ảnh có độ tương đồng lớn hơn hoặc bằng 90% với ảnh đầu vào mới được giữ lại trong kết quả tìm kiếm.

Sau khi chọn mô hình và đặt ngưỡng tương đồng phù hợp, hệ thống tiến hành phân loại ảnh. Trong bước này, ảnh đầu vào sẽ được tiền xử lý sao cho phù hợp với yêu cầu của mô hình đã chọn (chẳng hạn như thay đổi kích thước và chuẩn hóa pixel).

Tiếp theo, ảnh được đưa qua mô hình học sâu đã huấn luyện sẵn (ví dụ như VGG16, ResNet50, hoặc InceptionV3) để phân loại. Mỗi mô hình có lớp đầu ra ứng với một tập các lớp nhãn đã định nghĩa (như Charts, Maps, Others, Photographs, System_Model). Mô hình học sâu sẽ đưa ra một vector xác suất cho mỗi lớp nhãn, từ đó xác định lớp nào có xác suất cao nhất. Lớp có xác suất cao nhất sẽ được coi là dự đoán của mô hình đối với ảnh đầu vào. Đây là kết quả phân loại mà hệ thống đưa ra cho người dùng.

Sau khi phân loại, vector đặc trưng của ảnh sẽ được trích xuất từ mô hình dựa trên lớp *GlobalAveragePooling2D*. Vector đặc trưng này là biểu diễn số học của ảnh, chứa thông tin cần thiết để hệ thống có thể so sánh ảnh với các ảnh khác trong cơ sở dữ liệu.

Mỗi ảnh trong tập huấn luyện cũng đã được trích xuất vector đặc trưng từ trước và lưu trữ sẵn theo từng lớp phân loại. Sau khi ảnh đầu vào được phân loại và trích xuất vector đặc trưng, hệ thống sẽ so sánh vector này với các vector đã lưu thuộc lớp nhãn phân loại tương ứng để tính toán độ tương đồng. Để tính toán độ tương đồng giữa các ảnh, hệ thống sử dụng chỉ số Cosine Similarity, một phương pháp phổ biến để đo lường độ tương đồng giữa các vector.


Sau khi tính toán độ tương đồng, các ảnh sẽ được sắp xếp theo độ tương đồng giảm dần. Mỗi ảnh tương tự sẽ được lưu trữ với các thông tin bao gồm tên ảnh, độ tương đồng, và đường dẫn tới ảnh. Hệ thống chỉ giữ lại các ảnh có độ tương đồng vượt qua một ngưỡng nhất định do người dùng cài đặt. Sự sắp xếp này giúp hệ thống trả về các ảnh có độ tương đồng cao nhất với ảnh đầu vào, từ đó cung cấp cho người dùng các kết quả chính xác và hữu ích nhất.

Cuối cùng, sau khi hoàn tất quá trình tính toán độ tương đồng và sắp xếp các ảnh, hệ thống sẽ hiển thị kết quả cho người dùng. Trước tiên, hệ thống hiển thị ảnh đầu vào và cung cấp kết quả phân loại của ảnh đầu vào, với lớp nhãn có xác suất cao nhất được xác định thông qua mô hình học sâu đã huấn luyện. Tiếp theo, danh sách các ảnh tương tự trong tập ảnh lưu trữ sẽ được trình bày, sắp xếp theo thứ tự giảm dần của độ tương đồng. Mỗi ảnh tương tự sẽ đi kèm với thông tin chi tiết như tên ảnh, giá trị độ tương đồng so với ảnh đầu vào. Việc hiển thị trực quan kết quả này không chỉ hỗ trợ người dùng trong việc đánh giá nhanh mức độ tương tự, mà còn giúp quá trình tra cứu và khai thác dữ liệu hình ảnh trở nên thuận tiện và hiệu quả hơn.

3.2. Xây dựng các mô hình

3.2.1. Mô hình CNN

Convolutional Neural Networks (CNN) là một trong những kiến trúc mạng nơ-ron nhân tạo đặc biệt, chủ yếu được sử dụng để xử lý dữ liệu hình ảnh, video, và các dạng dữ liệu có cấu trúc không gian như tín hiệu âm thanh và chuỗi dữ liệu [7].



Hình 3.3. Cấu trúc đại diện của một mạng nơ ron tích chập.[7]

Cấu trúc điển hình của CNN Hình 3.3 bao gồm bốn loại lớp chính: Convolutional Layer, Activation Layer, Pooling Layer, và Fully Connected Layer.

Lớp tích chập (Convolutional Layer) là nền tảng cốt lõi của CNN, chịu trách nhiệm trích xuất các đặc trưng từ hình ảnh đầu vào. Bộ lọc (filter) sẽ trượt qua ảnh và tính toán phép tích chập giữa ảnh và bộ lọc đó. Công thức của phép tích chập hai chiều (1):

$$Y[i, j] = \sum_m \sum_n X[i + m, j + n] \cdot K[m, n] \quad (1)$$

Trong đó:

- X: Ma trận đầu vào biểu diễn hình ảnh.
- K: Ma trận kernel (bộ lọc).
- Y [i, j]: Giá trị đầu ra tại vị trí (i, j) sau khi thực hiện phép tích chập.

Sau khi thực hiện phép tích chập, dữ liệu sẽ đi qua **lớp kích hoạt (Activation Layer)** để thêm tính phi tuyến vào mô hình. Hàm kích hoạt phổ biến nhất là **ReLU** (Rectified Linear Unit) (2):

$$ReLU(x) = \max(0, x) \quad (2)$$

ReLU giúp loại bỏ các giá trị âm trong đầu ra của phép tích chập, giữ lại các giá trị dương và giúp tăng tốc quá trình huấn luyện.

Lớp gộp (Pooling Layer) có nhiệm vụ giảm kích thước không gian của bản đồ đặc trưng, giúp giảm số lượng tham số và tính toán trong mạng. Lớp gộp còn làm cho mô hình bền vững hơn với các phép biến đổi như dịch chuyển hoặc xoay ảnh. Phổ biến nhất là **Max Pooling**, với công thức (3):

$$Y[i, j] = \max(X[i: i + f, j: j + f]) \quad (3)$$

Trong đó f là kích thước của cửa sổ gộp.

Sau khi đi qua nhiều lớp tích chập và gộp, các bản đồ đặc trưng sẽ được làm phẳng thành một vector một chiều và đưa vào các **lớp hoàn toàn kết nối (Fully Connected Layer)**. Lớp này sử dụng hàm kích hoạt **softmax** cho các bài toán phân loại đa lớp (4):

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}} \quad (4)$$


Trong đó:

z_i : Đầu ra của nơ-ron tại lớp fully connected.

n : Số lớp phân loại đầu ra.

Bên cạnh các lớp, CNN còn có một số khái niệm: Stride, Padding, Filter (hay kernel), Feature Maps.


Stride là bước nhảy của cửa sổ tích chập khi nó di chuyển qua ảnh đầu vào. Giá trị stride quyết định tốc độ di chuyển của cửa sổ. Nếu stride bằng 1, cửa sổ tích chập sẽ di chuyển từng bước một qua các pixel, còn nếu stride bằng 2, cửa sổ sẽ di chuyển cách 2pixel một lần Hình 3.4.



Hình 3.4. Stride. [7]


Giá trị stride càng lớn, kích thước của đầu ra sẽ nhỏ hơn vì cửa sổ tích chập sẽ bỏ qua nhiều pixel hơn. Điều này có thể làm giảm độ phân giải của đầu ra, nhưng đồng thời giảm thiểu khối lượng tính toán.

Padding là kỹ thuật thêm các pixel giả (thường là giá trị 0, gọi là zero padding) xung quanh biên của ảnh đầu vào Hình 3.5. Điều này giúp duy trì kích thước đầu ra sau khi tích chập.



Hình 3.5. Padding. [7]

Filters hay còn gọi là kernels là các ma trận nhỏ được áp dụng lên ảnh đầu vào trong quá trình tích chập Hình 3.6. Các bộ lọc này thực hiện việc quét qua toàn bộ ảnh đầu vào, tính toán các giá trị mới dựa trên phép nhân tích chập giữa bộ lọc và các phần tương ứng của ảnh.




Hình 3.6. Filter (kernel)[7]

Feature Maps (Bản đồ đặc trưng) là kết quả đầu ra của một lớp tích chập sau khi áp dụng các bộ lọc lên ảnh đầu vào. Đây là nơi lưu trữ các đặc trưng đã được phát hiện bởi các bộ lọc trong quá trình tích chập.

Feature maps thể hiện sự hiện diện của các đặc trưng (như cạnh, góc) trong một bức ảnh tại các vị trí không gian khác nhau. Các feature maps càng sâu trong mạng CNN thì chứa các đặc trưng càng phức tạp, trừu tượng hơn.

3.2.2. Mô hình InceptionV3

Với kiến trúc đặc biệt và khả năng xử lý các đặc trưng phức tạp, InceptionV3 đã chứng minh hiệu quả vượt trội trong nhiều ứng dụng thực tế như nhận diện khuôn mặt, tìm kiếm ảnh, và phân loại hình ảnh.



Hình 3.7. Kiến trúc InceptionV3. [3]

Kiến trúc của InceptionV3 Hình 3.7 gồm các khối chính [3]:

Stem module: tuần tự 3 convolution 3x3, max-pool 3x3, 1 convolution 1x1, 1 convolution 3x3 và max-pool 3x3 làm giảm kích thước ảnh đầu vào và trích xuất các đặc trưng cơ bản.

Inception module A, B, C: gồm 4 nhánh song song. Các bộ lọc kích thước lần lượt là 1x1, 3x3, 7x7 được áp dụng trong Inception module giúp trích lọc được đa dạng đặc trưng trên những vùng nhận thức có kích thước khác nhau:

- **Inception-A:** Ở nhánh 1, 2, 4 từ trên xuống, convolution 1x1 được sử dụng nhằm mục đích giảm độ sâu kênh và số lượng tham số của mô hình. Sau đó ở nhánh 1 sử dụng 2 convolution 3x3 và ở nhánh 2 sử dụng 1 convolution 3x3 để trích xuất các đặc trưng cục bộ, nắm bắt các chi tiết trong hình ảnh. Nhánh thứ 3 từ trên xuống chúng ta giảm chiều dữ liệu bằng 1 avg-pool 3x3 và sau đó áp dụng convolution 1x1 để thay đổi số kênh.

Các nhánh áp dụng padding và stride sao cho đầu ra có cùng kích cỡ chiều dài và chiều rộng. Cuối cùng ta concatenate toàn bộ kết quả đầu ra của các khối theo kênh để thu được output có kích thước bằng với input.


- **Inception-B:** Cải tiến so với Inception-A. Thay convolution 1x1 bằng convolution 7x7 ở nhánh 1 và nhánh 2. Đồng thời chúng ta phân tích nhân tố convolution 7x7 thành 2 convolution liên tiếp 7x1 và 1x7 số lượng tham số sẽ ít hơn so với tích chập 2 convolution 3x3 liên tiếp. Nhờ đó số lượng tham số giảm từ 18 xuống còn 14.

- **Inception-C:** Cải tiến so với Inception-B. Thay convolution 7x1 bằng 3x1 và 1x7 bằng 1x3 và đồng thời thay vì đặt convolution 3x1 và 1x3 liên tiếp thì đặt chúng song song. Kiến trúc này giúp giảm số lượng tham số từ 14 về còn 6.

Reduction module A, B: Hai khối đặc biệt giúp giảm chiều kích thước không gian (spatial dimensions), nhằm tăng tốc tính toán và làm sâu mô hình hiệu quả.

3.2.3. Mô hình VGG16

Với kiến trúc đơn giản nhưng hiệu quả, VGG16 đã đạt kết quả ấn tượng trên tập dữ liệu ImageNet và được ứng dụng rộng rãi trong các bài toán như nhận dạng đối tượng, phân loại ảnh và phát hiện khuôn mặt. VGG16 nổi bật nhờ tính nhất quán trong kiến trúc và khả năng tái sử dụng các đặc trưng học được trong các nhiệm vụ khác nhau.



Hình 3.8. Kiến trúc VGG16.⁴

Kiến trúc VGG16 Hình 3.8 gồm các tầng chính:

Tầng tích chập (Convolutional Layers): gồm 13 tầng tích chập sử dụng kernel 3x3. Số lượng filters qua tầng dần qua các khối: 64 → 128 → 256 → 512.


Tầng pooling (Max Pooling): theo sau mỗi khối tích chập để giảm kích thước không gian. Khi đưa qua tầng này, kích thước ảnh sẽ giảm đi ½.

Tầng fully connected (FC): 3 tầng fully connected cuối cùng gồm 2 tầng 4096 đơn vị và 1 tầng đầu ra với số đơn vị bằng số lớp cần phân loại (ví dụ: 1000 cho ImageNet).

⁴ https://www.researchgate.net/figure/GG16-Architecture-Source-13_fig1_354024899

3.2.4. Mô hình ResNet50

Với kiến trúc sâu cùng cơ chế *residual learning*, ResNet50 đã chứng minh hiệu quả vượt trội trong việc xử lý các bài toán thị giác máy tính.



Hình 3.9. Kiến trúc ResNet50.⁵

Kiến trúc ResNet50 Hình 3.9 gồm các khối chính [5]:

Conv1: Một lớp convolution kích thước 7x7, 64 kênh, stride = 2, giúp giảm kích thước không gian của ảnh đầu vào và trích xuất các đặc trưng ban đầu.

Max pooling: giảm kích thước không gian.

Các khối Residual (Residual blocks): Bao gồm 4 nhóm với số lượng block lần lượt là [3, 4, 6, 3], sử dụng cấu trúc **bottleneck** gồm 3 lớp: Conv 1×1 (giảm chiều), Conv 3×3 (xử lý đặc trưng), Conv 1×1 (tăng chiều).

Average pooling: Gộp đặc trưng toàn cục trước khi đưa vào lớp phân loại.

Fully connected layer (FC): lớp đầu ra.

Softmax: Trả về xác suất phân phối qua các lớp.

3.3. Giải pháp cài đặt

Ngôn ngữ được lựa chọn sử dụng để tiến hành xây dựng hệ thống là Python. Đồng thời cài đặt các thành phần cần thiết để hỗ trợ:

- **Anaconda:** dùng để quản lý môi trường và cài đặt các gói phần mềm, đặc biệt là trong các dự án khoa học dữ liệu, học máy, và phân tích dữ liệu. Nó cung cấp một bộ công cụ mạnh mẽ giúp bạn dễ dàng quản lý các môi trường Python, cùng với các thư viện phổ biến như NumPy, Pandas, TensorFlow, và nhiều công cụ khác mà bạn có thể cần trong quá trình phát triển.

⁵ <https://srsapireddy.medium.com/resnet-50-introduction-b5435fdb66f>

- **Visual Studio code:** là môi trường phát triển mã nguồn mở miễn phí được thiết kế với giao diện lập trình trực quan, bắt mắt giúp thuận tiện hơn trong các thao tác lập trình.

- **Google Colab:** Là một nền tảng lập trình trực tuyến miễn phí do Google cung cấp, hỗ trợ chạy mã Python trực tiếp trên đám mây mà không cần cài đặt phần mềm cục bộ. Colab đặc biệt hữu ích cho việc thử nghiệm nhanh mô hình học máy, xử lý dữ liệu lớn và huấn luyện mạng nơ-ron nhờ có sẵn GPU/TPU miễn phí.

- Các thư viện:

+ **TensorFlow/Keras:** Sử dụng TensorFlow (hoặc Keras, API của TensorFlow) để xây dựng và triển khai các mô hình học sâu. TensorFlow cung cấp các công cụ hỗ trợ học sâu và tích hợp dễ dàng với mô hình tiền huấn luyện.

+ **NumPy:** Thư viện xử lý mảng cho các phép toán với dữ liệu ảnh.

+ **SciPy:** Thư viện để tính toán Cosine Similarity.

+ **OS:** Thư viện để tương tác với hệ thống tệp và thư mục (ví dụ: để làm việc với các đường dẫn tệp).

+ **PyMuPDF (fitz):** Thư viện trích xuất ảnh từ tệp PDF, giúp tự động hóa quá trình lấy dữ liệu hình ảnh từ tài liệu đầu vào.

+ **Flask:** Là framework Python nhẹ dùng để xây dựng giao diện web cho hệ thống. Flask giúp tạo trang web cho phép người dùng tải lên file ảnh, hiển thị ảnh, nhận dự đoán, xác suất dự đoán và hiển thị kết quả tìm kiếm ảnh tương đồng một cách trực quan và dễ sử dụng.

+ **Tkinter:** Thư viện GUI (giao diện người dùng đồ họa) của Python, được sử dụng để tạo các cửa sổ và giao diện người dùng (UI). (ví dụ: mở hộp thoại chọn tệp).

3.4. Tổng kết chương

Chương này đã mô tả chi tiết kiến trúc tổng quát của hệ thống xác định độ tương đồng ảnh, mô tả các cấu trúc của mô hình và đưa ra các công cụ và thư viện cần thiết để triển khai hệ thống. Nội dung này làm nền tảng cho việc triển khai và đánh giá hiệu quả của hệ thống ở các chương tiếp theo.

CHƯƠNG 4. KIỂM THỬ VÀ ĐÁNH GIÁ

4.1. Mục tiêu kiểm thử

Mục tiêu kiểm thử là để đánh giá hiệu suất của mô hình huấn luyện, đảm bảo hệ thống vận hành ổn định và chính xác, không có lỗi xảy ra. Kiểm thử giúp người lập trình phát hiện ra những bất thường và từ đó có thể đưa ra các giải pháp khắc phục phù hợp.

4.1.1. Mô tả tập dữ liệu.

Tập dữ liệu ảnh huấn luyện là những ảnh được trích xuất từ các tài liệu PDF bao gồm các hình ảnh như ảnh thực tế (photographs), biểu đồ (chart), bản đồ (maps), mô hình hệ thống (system models), hình ảnh khác (others) đã thu thập từ các bài nghiên cứu hay bài báo khoa học từ nhiều nguồn khác nhau.

Hình ảnh được trích xuất từ tài liệu PDF đã được định dạng ảnh tiêu chuẩn (PNG). Tuy nhiên, kích thước của các ảnh khi trích xuất khác nhau nên cần chuẩn hóa lại các ảnh về cùng một kích thước trước khi đưa qua mô hình học sâu nhằm đảm bảo tính đồng nhất đầu vào và tối ưu hiệu quả huấn luyện mô hình.

Tập dữ liệu gồm 4599 ảnh, được trích xuất từ 1107 tệp tài liệu PDF, thu thập từ tạp chí khoa học Đại học Cần Thơ, bao gồm cả bài báo **tiếng Việt**⁶ và **tiếng Anh**⁷, được phân loại thành 5 nhóm chính Bảng 4.1 dựa trên nội dung và đặc điểm:

- Chart: các biểu đồ như biểu đồ tròn, biểu đồ cột, biểu đồ miền, ...
- Photograph: các hình ảnh chụp thực tế.
- Maps: các bản đồ địa lý.
- System_Model: các mô hình hệ thống.
- Others: các hình ảnh khác không thuộc 4 nhóm trên.

Bảng 4.1. Số lượng ảnh được gán nhãn.

Nhãn	Số lượng ảnh
Chart	1533
Photograph	1762
Maps	208
System_Model	821
Others	275

⁶ <https://ctujsvn.ctu.edu.vn/>

⁷ <https://ctujs.ctu.edu.vn/>

Để đảm bảo mô hình được huấn luyện, theo dõi và điều chỉnh cũng như đánh giá hiệu suất mô hình thì tập dữ liệu được chia thành tập huấn luyện (train), tập kiểm tra (validation), tập kiểm thử (test) theo tỉ lệ 80:10:10 Bảng 4.2.

Bảng 4.2. Số lượng ảnh sau khi chia.

Tập dữ liệu	Số lượng ảnh
Train	3217
Validation	688
Test	694

4.1.2. Các tham số huấn luyện mô hình.

Để huấn luyện các mô hình học sâu đạt hiệu quả cao và ổn định, việc lựa chọn các tham số huấn luyện phù hợp đóng vai trò rất quan trọng. Chúng đảm bảo quá trình tối ưu hóa diễn ra hiệu quả, mô hình học được đặc trưng quan trọng từ dữ liệu, đạt được độ chính xác cao trên tập kiểm thử, đồng thời hạn chế được các vấn đề thường gặp như quá khớp (overfitting) hoặc kém khớp (underfitting). Các tham số được sử dụng trong quá trình huấn luyện được trình bày ở Bảng 4.3.

Bảng 4.3. Tham số huấn luyện mô hình.

Tham số	Giá trị	Mô tả
Num_class	5	Số lớp tham gia huấn luyện.
Số epoch	50	Số lần toàn bộ tập dữ liệu được sử dụng để huấn luyện mô hình.
Batch size	32	Số lượng mẫu dữ liệu trong một batch.
Optimizer	Adam	Thuật toán tối ưu.
Activation	Relu	Hàm kích hoạt.
Learning rate	0.0001	Tốc độ học của mô hình.
EarlyStopping	Patience = 5 Monitor = val_loss	Cơ chế dừng huấn luyện sớm nếu không thấy cải thiện trên tập validation trong một số epoch nhất định.
ReduceLROnPlateau	Factor = 0.2 Patience = 2	Cơ chế giảm tốc độ học khi mô hình không cải thiện trong một số epoch.
Class weight	Có sử dụng – tính theo tỉ lệ lớp	Điều chỉnh trọng số của các lớp trong trường hợp dữ liệu không cân bằng.

Dưới đây là phần **giải thích chi tiết** các tham số trong bảng:

Num_class: xác định số lớp đầu ra trong bài toán phân loại ảnh. Trong nghiên cứu này, hệ thống được huấn luyện để phân loại 5 loại ảnh khác nhau. Tham số này phải phù hợp với số nhãn trong dữ liệu để đảm bảo huấn luyện chính xác.

Số epoch: quy định số lần toàn bộ tập dữ liệu được sử dụng để huấn luyện mô hình. Chọn số lượng epoch phù hợp giúp mô hình học đủ các đặc trưng quan trọng trong dữ liệu mà không bị quá khớp. Nếu số epoch quá nhỏ, mô hình có thể chưa học đủ (underfitting); ngược lại nếu quá lớn, mô hình có nguy cơ nhớ quá kỹ dữ liệu huấn luyện (overfitting). Trong nghiên cứu này, 50 epoch là con số vừa đủ để quan sát xu hướng hội tụ và kiểm soát tốt overfitting nhờ các kỹ thuật hỗ trợ như EarlyStopping.

Batch_size: số lượng mẫu được xử lý trước khi mô hình cập nhật trọng số. Với $batch_size = 32$, mô hình có thể tận dụng tốt tài nguyên tính toán, đồng thời giúp quá trình cập nhật gradient ổn định hơn so với batch quá nhỏ (dễ nhiễu) hay quá lớn (tốn tài nguyên, chậm phản ứng với thay đổi). Batch size ảnh hưởng trực tiếp đến tốc độ huấn luyện và khả năng hội tụ của mô hình.

Optimizer – Adam (Adaptive Moment Estimation)⁸: thuật toán tối ưu hóa phổ biến trong học sâu do khả năng điều chỉnh tốc độ học riêng biệt cho từng tham số trong mạng. Nó kết hợp giữa Momentum và RMSProp, giúp tăng tốc độ hội tụ và tránh bị kẹt tại các điểm tối ưu cục bộ. Adam thường cho kết quả tốt mà không cần điều chỉnh nhiều siêu tham số, đặc biệt hữu ích khi huấn luyện trên dữ liệu không đồng đều hoặc có nhiễu.

Activation – ReLU: hàm kích hoạt phi tuyến tính giúp mô hình học được mối quan hệ phức tạp trong dữ liệu, đồng thời đơn giản về mặt tính toán và tránh hiện tượng gradient biến mất.

Learning_rate: xác định tốc độ học của mô hình giúp kiểm soát mức độ cập nhật trọng số trong mỗi bước học. Trong nghiên cứu này, thuật toán tối ưu Adam được sử dụng với giá trị learning rate là 0.0001, giúp quá trình huấn luyện diễn ra ổn định và hiệu quả. Đồng thời, việc kết hợp với cơ chế ReduceLROnPlateau cho phép learning rate tự động giảm khi mô hình không cải thiện sau một số epoch nhất định. Điều này giúp mô hình hội tụ nhanh hơn và hạn chế tình trạng overfitting, từ đó nâng cao khả năng tổng quát của mô hình trên dữ liệu mới.

EarlyStopping⁹: Một kỹ thuật giúp dừng huấn luyện sớm nếu mô hình không còn cải thiện về hiệu suất trên tập validation trong một số epoch liên tiếp, giúp tiết kiệm thời gian huấn luyện và tránh hiện tượng overfitting. Khi không thấy cải thiện trên tập validation (theo val_loss) trong một số epoch liên tiếp ($patience = 5$), quá trình huấn luyện sẽ dừng.

⁸ <https://viblo.asia/p/optimizer-hieu-sau-ve-cac-thuat-toan-toi-uu-gdsgdadam-Qbq5QQ9E5D8>

⁹ https://keras.io/api/callbacks/early_stopping/

lại tự động. Điều này đặc biệt hữu ích trong trường hợp mô hình bắt đầu ghi nhớ dữ liệu huấn luyện thay vì học tổng quát hóa.

ReduceLROnPlateau¹⁰: Nếu trong quá trình huấn luyện mô hình không cải thiện (theo *val_loss*), thuật toán sẽ giảm learning rate theo một hệ số (*factor* = 0.2) sau một số epoch không cải thiện (*patience* = 2). Việc này giúp mô hình “học chậm lại” để tinh chỉnh tốt hơn ở giai đoạn cuối, tránh nhảy qua các điểm cực tiểu tốt.

Class_weight: Trong trường hợp dữ liệu không cân bằng giữa các lớp (ví dụ có lớp nhiều ảnh hơn lớp khác), mô hình có xu hướng lệch về các lớp có số mẫu nhiều hơn. Việc sử dụng class weight – tính toán theo tỷ lệ lớp – giúp cân bằng ảnh hưởng của từng lớp trong quá trình huấn luyện, từ đó cải thiện độ chính xác, đặc biệt là trên các lớp ít dữ liệu hơn. Điều này cũng góp phần nâng cao độ tin cậy của chỉ số F1-score khi đánh giá toàn cục.

4.1.3. Môi trường thực nghiệm.

Nghiên cứu được thực hiện dựa trên nền tảng ngôn ngữ lập trình Python. Quá trình huấn luyện mô hình được triển khai trên Google Colab, tận dụng hiệu năng của GPU miễn phí trong môi trường điện toán đám mây. Các thư viện mã nguồn mở như TensorFlow và Keras được sử dụng để xây dựng và huấn luyện các mô hình mạng nơ-ron sâu, hỗ trợ tối ưu hóa việc xử lý và phân tích dữ liệu hình ảnh.

Sau khi huấn luyện, mô hình được lưu và tải xuống môi trường cục bộ để triển khai quy trình phân loại ảnh và tính tương đồng ảnh. Môi trường này được thiết lập trên Anaconda kết hợp với Visual Studio Code, cung cấp nền tảng thuận tiện và ổn định để triển khai ứng dụng thực tế. Mô hình học sâu đã huấn luyện sẽ được tích hợp vào một ứng dụng Flask, thực hiện các tác vụ như phân loại ảnh và tìm kiếm ảnh tương đồng.


4.1.4. Các độ đo đánh giá thực hiện.

Trong nghiên cứu này, các mô hình học sâu gồm InceptionV3, VGG16 và ResNet50 được xây dựng nhằm phân loại ảnh đầu vào và tìm kiếm ảnh tương đồng với tập ảnh được trích xuất từ PDF. Việc đánh giá hiệu suất của từng mô hình là bước quan trọng để đảm bảo rằng mô hình hoạt động tốt trên dữ liệu thực tế. Các độ đo đánh giá hiệu suất được sử dụng trong nghiên cứu gồm: Confusion Matrix, Accuracy, Precision, Recall, F1-Score. [8]

Confusion Matrix (Ma trận nhầm lẫn): là một công cụ dùng để đánh giá hiệu suất của một mô hình phân loại. Nó hiển thị số lần mô hình dự đoán đúng và sai cho từng lớp, giúp bạn dễ dàng hiểu rõ mô hình phân loại chính xác hay sai lệch như thế nào.

Confusion Matrix là một bảng hình vuông với các giá trị thể hiện kết quả của mô hình phân loại Hình 4.1:

¹⁰ https://pytorch.org/docs/stable/generated/torch.optim.lr_scheduler.ReduceLROnPlateau.html



Hình 4.1. Confusion Matrix ¹¹

Trong đó:

- **TP (True Positives)**: Số lượng mẫu thực tế thuộc lớp đó và được mô hình dự đoán đúng. Ví dụ: Một hình ảnh là “Chart” được dự đoán là “Chart”.

- **FP (False Positives)**: Số lượng mẫu không thuộc lớp đó nhưng mô hình lại dự đoán là lớp đó. Ví dụ: Một hình ảnh không phải là “Chart” nhưng được dự đoán là “Chart”.

- **TN (True Negatives)**: Số lượng mẫu mà mô hình dự đoán đúng là không thuộc lớp đó. Ví dụ: Một hình ảnh không phải là “Chart” và cũng được dự đoán không phải là “Chart”.

- **FN (False Negatives)**: Số lượng mẫu thực tế thuộc lớp đó nhưng bị mô hình dự đoán sai (dự đoán là các lớp khác). Ví dụ: Một hình ảnh là “Chart” được dự đoán là “System_Model”.

Accuracy (độ chính xác): biểu thị tỷ lệ phần trăm các dự đoán đúng so với tổng số mẫu dữ liệu được dự đoán. Công thức tính độ chính xác (5):

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

Precision (độ chính xác của dự đoán): biểu thị tỷ lệ mẫu được dự đoán đúng (TP) trên tổng số mẫu dự đoán thuộc một lớp (kể cả những mẫu bị dự đoán sai FP). Công thức tính độ chính xác của dự đoán (6):

$$Precision = \frac{TP}{TP + FP} \quad (6)$$

¹¹ <https://medium.com/@RobuRishabh/classification-measures-in-machine-learning-fe293feaa358>

Recall (độ nhạy): biểu thị tỷ lệ mẫu được dự đoán đúng (TP) trên tổng số mẫu thuộc lớp đó trong tập dữ liệu (kể cả mẫu bị dự đoán nhầm FN). Công thức tính độ nhạy (7):

$$Recall = \frac{TP}{TP + FN} \quad (7)$$

F1-Score: là một chỉ số tổng hợp giữa Precision (Độ chính xác theo dự đoán) và Recall (Độ nhạy), đặc biệt hữu ích trong các bài toán phân loại mất cân bằng dữ liệu, được tính bằng trung bình điều hòa của Precision và Recall. Công thức tính F1-Score (8):

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (8)$$

4.1.5. Độ đo tương đồng hình ảnh.

Trong nghiên cứu này, **Cosine Similarity** được lựa chọn để tính toán mức độ tương đồng giữa các ảnh, nhờ khả năng hoạt động ổn định với các vector đặc trưng chiều cao được trích xuất từ mô hình học sâu. Công thức tính **Cosine Similarity** (9):

$$Cosine\ Similarity(A, B) = \frac{A \times B}{\|A\| \|B\|} \quad (9)$$

Trong đó:

A và B là các vector đặc trưng của hai hình ảnh cần so sánh.

$A \times B$ là phép nhân vô hướng giữa hai vector.

$\|A\|$ và $\|B\|$ là độ dài của các vector A và B.

Cosine Similarity đo lường góc giữa hai vector đặc trưng, và có giá trị trong khoảng từ -1 đến 1. Giá trị 1 nghĩa là hai hình ảnh hoàn toàn giống nhau về mặt đặc trưng, giá trị 0 nghĩa là không có sự tương đồng giữa hai hình ảnh, giá trị -1 nghĩa là hai hình ảnh có đặc trưng đối nghịch.

4.1.6. Kịch bản kiểm thử.

Kịch bản 1: Đánh giá hiệu suất mô hình phân loại InceptionV3.

Kịch bản 2: Đánh giá hiệu suất mô hình phân loại VGG16.

Kịch bản 3: Đánh giá hiệu suất mô hình phân loại ResNet50.


Kịch bản 4: Kiểm thử phân loại ảnh và tính độ tương đồng.

4.2. Kết quả kiểm thử

4.2.1. Kết quả kiểm thử kịch bản 1: Đánh giá hiệu suất mô hình phân loại InceptionV3

Mô hình phân loại ảnh được huấn luyện với số lượng epoch tối đa là 50, đồng thời tích hợp hai kỹ thuật điều khiển quá trình học gồm EarlyStopping và ReduceLROnPlateau nhằm tránh overfitting và tối ưu hiệu quả hội tụ. Biểu đồ Hình 4.2 dưới đây thể hiện rõ quá trình huấn luyện của mô hình, bao gồm độ chính xác (accuracy) và giá trị hàm mất mát

(loss) trên cả tập huấn luyện và validation qua các epoch. Ngoài ra, biểu đồ cũng đánh dấu rõ **mốc epoch tốt nhất** theo tiêu chí của kỹ thuật **EarlyStopping**, tại đó mô hình đạt giá trị mất mát trên tập validation thấp nhất trước khi dừng huấn luyện sớm nhằm tránh hiện tượng overfitting.



Hình 4.2. Biểu đồ trực quan hóa hiệu suất của mô hình InceptionV3.

Ngay từ những epoch đầu tiên, mô hình cho thấy khả năng học rất tốt. Ở epoch đầu tiên, độ chính xác huấn luyện đạt 69%, trong khi độ chính xác trên tập validation đã lên tới 89%. Trong các epoch tiếp theo, mô hình nhanh chóng đạt được độ chính xác trên tập huấn luyện trên 97% (từ epoch 5), và tiệm cận 99–100% từ epoch 8 trở đi. Tuy nhiên, độ chính xác trên tập validation chỉ dao động quanh mức 94.12%, trong khi giá trị loss validation bắt đầu dừng giảm và dao động nhẹ từ epoch 7 trở đi và đạt giá trị thấp nhất tại epoch 9 là 0.2678.

Như có thể thấy trong biểu đồ Hình 4.2, độ chính xác validation ổn định ở mức 94.12% từ epoch 9, trong khi giá trị loss validation không tiếp tục giảm sau đó. Điều này chỉ ra rằng mô hình đã học gần như tối đa khả năng trên tập huấn luyện nhưng không cải thiện thêm về khả năng khái quát hóa.


Kể từ epoch 9, val_loss không còn cải thiện thêm trong 5 epoch liên tiếp, dẫn đến việc EarlyStopping được kích hoạt tại epoch 14, kết thúc quá trình huấn luyện sớm hơn so với kế hoạch. Đây là dấu hiệu cho thấy mô hình đã bắt đầu rơi vào overfitting nhẹ, khi tiếp tục học tốt trên tập huấn luyện nhưng không cải thiện thêm về khả năng khái quát hóa.

Việc sử dụng ReduceLROnPlateau trong quá trình huấn luyện giúp tự động điều chỉnh learning rate giảm dần từ 1×10^{-4} xuống 1×10^{-6} , giúp duy trì sự ổn định khi mô hình không còn cải thiện rõ rệt.

Dựa trên kết quả huấn luyện, epoch thứ 9 được lựa chọn là mốc tốt nhất, với độ chính xác validation (94.12%) và giá trị mất mát thấp nhất (val_loss = 0.2678). Đây là phiên bản mô hình được lưu lại để phục vụ cho bước trích xuất đặc trưng và suy luận sau này.

Sau khi đã đánh giá hiệu suất tổng thể của mô hình thông qua các biểu đồ trực quan hóa về độ chính xác và hàm mất mát, tiếp tục tiến hành phân tích ma trận nhầm lẫn được chuẩn hóa theo tỷ lệ phần trăm Hình 4.3 để hiểu rõ hơn về cách thức mà mô hình phân loại các lớp. Ma trận nhầm lẫn chuẩn hóa biểu diễn tỷ lệ phần trăm dự đoán đúng và sai thay vì số lượng mẫu tuyệt đối. Mỗi hàng trong ma trận tương ứng với một lớp thực tế, còn mỗi cột thể hiện lớp được mô hình dự đoán. Giá trị trong từng ô biểu thị tỷ lệ phần trăm mẫu của một lớp cụ thể được dự đoán vào một lớp nào đó.

Các ô nằm trên đường chéo chính thể hiện tỷ lệ dự đoán đúng của mô hình cho từng lớp (cũng chính là giá trị Recall của từng lớp), trong khi các ô ngoài đường chéo phản ánh mức độ nhầm lẫn giữa các lớp. Việc sử dụng ma trận theo tỷ lệ giúp dễ dàng so sánh hiệu suất giữa các lớp, đặc biệt hữu ích trong các bài toán phân loại không cân bằng, khi số lượng mẫu giữa các lớp chênh lệch đáng kể. Nhờ đó, ta có thể phát hiện những lớp mô hình xử lý chưa tốt để từ đó có hướng cải thiện phù hợp.



Hình 4.3. Ma trận nhầm lẫn theo tỷ lệ từng lớp của InceptionV3.

Dựa trên ma trận nhầm lẫn (Confusion Matrix) của InceptionV3 Hình 4.3, mô hình đạt hiệu suất khá tốt với tỷ lệ dự đoán đúng trên từng lớp dao động trong khoảng 71%-98%. Cụ thể, đối với các lớp như Charts và Photographs đạt độ chính xác cao nhất, lần lượt là 97% và 98%. Đây là các lớp dễ nhận dạng hơn, có thể do chúng sở hữu các đặc điểm đặc trưng nổi bật và ít bị trùng lặp với các lớp khác. Các nhầm lẫn chủ yếu là giữa lớp Others và lớp System_Model, nhưng tỷ lệ này rất thấp. Lớp Maps cũng đạt độ chính xác cao 95%, tuy nhiên có một tỷ lệ nhỏ mẫu bị nhầm thành lớp System_Model.

Bên cạnh đó, lớp System_Model có độ chính xác thấp hơn (87%). Phần lớn nhầm lẫn xảy ra với lớp Charts cho thấy rằng các đặc điểm hình ảnh của chúng có sự tương đồng nhất định. Lớp Others có độ chính xác thấp nhất với 71%, có thể do lớp này chứa nhiều ảnh không có đặc trưng rõ ràng.

Nhìn chung, mô hình phân loại ảnh có khả năng phân biệt các lớp rõ ràng với độ chính xác cao, tuy nhiên, vẫn còn một số nhầm lẫn nhất định giữa các lớp có đặc điểm tương tự. Mô hình đã thể hiện khả năng học đặc trưng và khái quát hóa tốt trên dữ liệu kiểm thử, với hiệu suất cao và ổn định.

Sau khi hoàn tất việc huấn luyện mô hình, tiến hành đánh giá hiệu suất trên tập kiểm thử (test) qua Bảng 4.4. Bảng thể hiện các chỉ số đánh giá hiệu suất precision, recall, f1-score, accuracy, support (số lượng mẫu) cho từng lớp nhãn và cung cấp độ chính xác tổng thể và các trung bình có trọng số.

Bảng 4.4. Các chỉ số đánh giá hiệu suất mô hình InceptionV3.

	Precision	Recall	F1-score	Accuracy	Support
Charts	0.96	0.97	0.96	0.97	154
Maps	0.83	0.95	0.89	0.99	21
Others	0.80	0.71	0.75	0.97	28
Photographs	0.98	0.98	0.98	0.98	177
System_Model	0.90	0.87	0.88	0.96	83
accuracy	0.94	0.94	0.94		0.94
macro avg	0.89	0.90	0.89		463
weighted avg	0.94	0.94	0.94		463

Độ chính xác theo từng lớp: Lớp “Charts” có độ chính xác 97% trên 154 ảnh. Lớp “Maps” có độ chính xác 99% trên 21 ảnh. Lớp “Others” có độ chính xác 97% trên 28 ảnh. Lớp “Photographs” có độ chính xác 98% trên 177 ảnh. Lớp “System_Model” có độ chính xác 96% trên 83 ảnh. Những con số này cho thấy mô hình này có hiệu suất rất tốt trên các lớp.

Độ chính xác tổng thể (accuracy) đạt 94% trên tập kiểm thử, đồng nghĩa với việc chỉ có 6% mẫu bị phân loại sai. Đây là một kết quả tốt, phản ánh rằng mô hình hoạt động ổn định và hiệu quả khi áp dụng vào dữ liệu chưa từng thấy trước đó.

Độ chính xác của dự đoán (Precision) tỷ lệ mẫu được dự đoán đúng (TP) trên tổng số mẫu dự đoán thuộc một lớp. Precision trung bình (weighted avg) đạt 94% cho thấy mô hình có xu hướng dự đoán khá chính xác với đa số các lớp. Một số lớp có precision rất cao,


ví dụ như lớp “Photographs” đạt 0.98 và “Charts” đạt 0.96 nghĩa là trong số các ảnh được dự đoán là “Photographs” có 98% dự đoán đúng và dự đoán là “Charts” có 96% dự đoán đúng. Tuy nhiên, “Others” có precision thấp nhất (0.80) cho thấy mô hình thường dự đoán nhầm các lớp khác thành lớp này do lớp này chứa nhiều ảnh không có đặc trưng rõ ràng.

Độ nhạy (Recall): biểu thị tỷ lệ mẫu được dự đoán đúng (TP) trên tổng số mẫu thuộc lớp đó trong tập dữ liệu. Recall trung bình (weighted avg) đạt 94% cho thấy mô hình có khả năng nhận diện tốt phần lớn các lớp. Lớp “Photographs” và “Charts” tiếp tục nổi bật với recall rất cao (0.98, 0.97) chứng tỏ mô hình ít bỏ sót các ảnh thuộc hai lớp này. Tuy nhiên, lớp “System_Model” chỉ đạt 0.87, nghĩa là mô hình bỏ sót khá nhiều mẫu thật sự thuộc lớp này và lớp “Others” cũng chỉ đạt 0.71, cho thấy khả năng bao phủ của mô hình với lớp này còn hạn chế.

F1-score: là trung bình điều hòa giữa precision và recall, cho thấy mức độ cân bằng giữa độ chính xác và độ bao phủ của mô hình trong từng lớp. F1-score trung bình (weighted avg) đạt 94% cho thấy mô hình vừa có độ chính xác cao, vừa bao phủ tốt trên toàn bộ tập kiểm tra. Lớp “Photographs” đạt F1-score cao nhất 0.98 phản ánh sự ổn định và hiệu quả vượt trội trong việc nhận diện lớp này. Lớp “Others” đạt F1-score thấp nhất (0.75) cho thấy sự mất cân bằng trong precision và recall và cần được cải thiện.

4.2.2. Kết quả kiểm thử kịch bản 2: Đánh giá hiệu suất mô hình phân loại VGG16.

Tương tự với mô hình InceptionV3, mô hình phân loại ảnh VGG16 cũng được huấn luyện với số lượng epoch tối đa là 50 và tích hợp hai kỹ thuật điều khiển quá trình học gồm EarlyStopping và ReduceLROnPlateau nhằm tránh overfitting và tối ưu hiệu quả hội tụ. Biểu đồ Hình 4.4 dưới đây thể hiện rõ quá trình huấn luyện của mô hình, bao gồm độ chính xác (accuracy) và giá trị hàm mất mát (loss) trên cả tập huấn luyện và validation qua các epoch. Ngoài ra, biểu đồ cũng đánh dấu rõ mốc epoch tốt nhất theo tiêu chí của kỹ thuật EarlyStopping, tại đó mô hình đạt giá trị mất mát trên tập validation thấp nhất trước khi dừng huấn luyện sớm nhằm tránh hiện tượng overfitting.




Hình 4.4. Biểu đồ trực quan hóa hiệu suất của mô hình VGG16.

Ngay từ những epoch đầu tiên, mô hình đã bắt đầu cải thiện dần. Ở epoch đầu tiên, độ chính xác huấn luyện đạt 54.17% và độ chính xác trên tập validation đạt 73.64%. Tuy nhiên, trong các epoch tiếp theo, mô hình dần cải thiện hiệu suất huấn luyện, đạt trên 90% (từ epoch 4), và tiếp tục cải thiện lên gần 97-98% trong các epoch tiếp theo. Tuy nhiên, độ chính xác trên tập validation chỉ dao động quanh mức 90-92%, trong khi giá trị loss validation bắt đầu dừng giảm và dao động nhẹ từ epoch 4 trở đi và đạt giá trị thấp nhất tại epoch 7 là 0.3748.

Kể từ epoch 7 trở đi, **validation loss** không còn cải thiện thêm trong 5 epoch liên tiếp dẫn đến việc EarlyStopping được kích hoạt tại epoch 12, kết thúc quá trình huấn luyện sớm hơn so với kế hoạch. Việc duy trì mô hình học tiếp sau epoch 7 có thể không mang lại thêm lợi ích rõ rệt và có thể dẫn đến **overfitting nhẹ** nếu tiếp tục kéo dài quá trình huấn luyện.

Dựa trên kết quả huấn luyện, epoch thứ 7 được lựa chọn là mốc tốt nhất, với độ chính xác validation (92.81%) và giá trị mất mát thấp nhất ($\text{val_loss} = 0.3748$). Đây là phiên bản mô hình được lưu lại để phục vụ cho bước trích xuất đặc trưng và suy luận sau này.

Sau khi đã đánh giá hiệu suất tổng thể của mô hình thông qua các biểu đồ trực quan hóa về độ chính xác và hàm mất mát, tiếp tục tiến hành phân tích ma trận nhầm lẫn được chuẩn hóa theo tỷ lệ phần trăm Hình 4.5 để hiểu rõ hơn về cách thức mà mô hình phân loại các lớp.



Hình 4.5. Ma trận nhầm lẫn theo tỷ lệ từng lớp của VGG16.

Dựa trên ma trận nhầm lẫn (Confusion Matrix) của VGG16 Hình 4.5, mô hình đạt hiệu suất khá tốt với tỷ lệ dự đoán đúng trên từng lớp dao động trong khoảng 86%-96%, ngoại trừ lớp Others đạt 68% do số mẫu ít và không có đặc điểm nổi bật. Cụ thể, đối với các lớp như Charts và Photographs đạt độ chính xác cao nhất, đạt 96%. Đây là các lớp dễ nhận dạng hơn, có thể do chúng sở hữu các đặc điểm đặc trưng nổi bật và ít bị trùng lặp với các lớp khác.

Bên cạnh đó, lớp Maps và System_Model có độ chính xác thấp hơn, đạt 86%. Phần lớn nhầm lẫn xảy ra với lớp Charts cho thấy rằng các đặc điểm hình ảnh của chúng có sự tương đồng nhất định. Lớp Others có độ chính xác thấp nhất với 68%, có thể do lớp này chứa nhiều ảnh không có đặc trưng rõ ràng.

Nhìn chung, mô hình phân loại ảnh có khả năng phân biệt các lớp rõ ràng với độ chính xác cao, tuy nhiên, vẫn còn một số nhầm lẫn nhất định giữa các lớp có đặc điểm tương tự. Mô hình đã thể hiện khả năng học đặc trưng và khái quát hóa tốt trên dữ liệu kiểm thử, với hiệu suất cao và ổn định.

Sau khi hoàn tất việc huấn luyện mô hình, tiến hành đánh giá hiệu suất trên tập kiểm thử (test) qua Bảng 4.5. Bảng thể hiện các chỉ số đánh giá hiệu suất precision, recall, f1-score, accuracy, support (số lượng mẫu) cho từng lớp nhãn và cung cấp độ chính xác tổng thể và các trung bình có trọng số.

Bảng 4.5. Các chỉ số đánh giá hiệu suất mô hình VGG16.

	Precision	Recall	F1-score	Accuracy	Support
Charts	0.91	0.96	0.93	0.95	154
Maps	0.90	0.86	0.88	0.99	21
Others	0.79	0.68	0.73	0.97	28
Photographs	0.98	0.96	0.97	0.98	177
System_Model	0.87	0.86	0.86	0.95	83
accuracy	0.92	0.92	0.92		0.92
macro avg	0.89	0.86	0.87		463
weighted avg	0.92	0.92	0.92		463

Độ chính xác theo từng lớp: Lớp “Charts” có độ chính xác 95% trên 154 ảnh. Lớp “Maps” có độ chính xác 99% trên 21 ảnh. Lớp “Others” có độ chính xác 97% trên 28 ảnh. Lớp “Photographs” có độ chính xác 98% trên 177 ảnh. Lớp “System_Model” có độ chính xác 95% trên 83 ảnh. Những con số này cho thấy mô hình này có hiệu suất rất tốt trên các lớp.

Độ chính xác tổng thể (accuracy) đạt 92% trên tập kiểm thử, đồng nghĩa với việc chỉ có 8% mẫu bị phân loại sai. Đây là một kết quả tốt, phản ánh rằng mô hình hoạt động ổn định và hiệu quả khi áp dụng vào dữ liệu chưa từng thấy trước đó.


Độ chính xác của dự đoán (Precision) trung bình (weighted avg) đạt 92% cho thấy mô hình có xu hướng dự đoán khá chính xác với đa số các lớp. Lớp “Photographs” có precision rất cao (0.98) nghĩa là trong số các ảnh được dự đoán là “Photographs” có 98% dự đoán đúng. Tuy nhiên, “Others” có precision thấp nhất (0.79) cho thấy mô hình thường dự đoán nhầm các lớp khác thành lớp này do lớp này chứa nhiều ảnh không có đặc trưng rõ ràng.

Độ nhạy (Recall) trung bình (weighted avg) đạt 92% cho thấy mô hình có khả năng nhận diện tốt phần lớn các lớp. Lớp “Photographs” và “Charts” tiếp tục nổi bật với recall rất cao (0.96) chứng tỏ mô hình ít bỏ sót các ảnh thuộc hai lớp này. Tuy nhiên, lớp “Others” cũng chỉ đạt 0.68, cho thấy khả năng bao phủ của mô hình với lớp này còn hạn chế.

F1-score trung bình (weighted avg) đạt 92% cho thấy mô hình vừa có độ chính xác cao, vừa bao phủ tốt trên toàn bộ tập kiểm tra. Lớp “Photographs” đạt F1-score cao nhất 0.97 phản ánh sự ổn định và hiệu quả vượt trội trong việc nhận diện lớp này. Lớp “Others” đạt F1-score thấp nhất (0.73) cho thấy sự mất cân bằng trong precision và recall và cần được cải thiện.

4.2.3. Kết quả kiểm thử kịch bản 3: Đánh giá hiệu suất mô hình phân loại ResNet50.

Tương tự với 2 mô hình trên, mô hình phân loại ảnh ResNet50 cũng được huấn luyện với số lượng epoch tối đa là 50 và tích hợp hai kỹ thuật điều khiển quá trình học nhằm tránh overfitting và tối ưu hiệu quả hội tụ. Biểu đồ Hình 4.6 dưới đây thể hiện rõ quá trình huấn luyện của mô hình, bao gồm độ chính xác (accuracy) và giá trị hàm mất mát (loss) trên cả tập huấn luyện và validation qua các epoch. Ngoài ra, biểu đồ cũng đánh dấu rõ **mốc epoch tốt nhất** theo tiêu chí của kỹ thuật **EarlyStopping**, tại đó mô hình đạt giá trị mất mát trên tập validation thấp nhất trước khi dừng huấn luyện sớm nhằm tránh hiện tượng overfitting.



Hình 4.6. Biểu đồ trực quan hóa hiệu suất của mô hình ResNet50.


Ngay từ những epoch đầu tiên, mô hình cho thấy khả năng học rất tốt. Ở epoch đầu tiên, độ chính xác huấn luyện đạt 60.81%, trong khi độ chính xác trên tập validation đã lên tới 81.70%. Điều này cho thấy mô hình đã nhanh chóng học được đặc trưng ban đầu của tập dữ liệu. Từ epoch 2 đến epoch 13, độ chính xác huấn luyện liên tục cải thiện và vượt mốc 90%, trong khi độ chính xác kiểm định dao động ổn định quanh mức 87–89%. Mặc dù độ chính xác huấn luyện tiếp tục tăng, độ chính xác trên tập validation không có sự cải thiện rõ rệt, cho thấy mô hình đang dần tiến đến trạng thái hội tụ. Trong giai đoạn này, giá trị hàm mất mát trên tập kiểm định (validation loss) có xu hướng chững lại và bắt đầu dao động nhẹ từ **epoch 10 trở đi** và đạt giá trị thấp nhất tại **epoch 13** là 0.2751.

Từ **epoch 14 đến epoch 18**, mặc dù tốc độ học đã giảm và độ chính xác huấn luyện tiếp tục tăng (đạt tới gần 96%), **validation accuracy dao động nhẹ trong khoảng 89–90%** nhưng không vượt trội so với trước đó. Đồng thời, **validation loss** không còn cải thiện thêm. Điều này cho thấy mô hình bắt đầu rơi vào trạng thái học chậm và có dấu hiệu **tiềm cận** về hiệu năng. Việc duy trì mô hình học tiếp sau epoch 13 có thể không mang lại thêm lợi ích rõ rệt và có thể dẫn đến **overfitting nhẹ** nếu tiếp tục kéo dài quá trình huấn

luyện. Vì vậy, EarlyStopping được kích hoạt tại epoch 18 sau 5 epoch val_loss không cải thiện, kết thúc quá trình huấn luyện sớm hơn so với kế hoạch.

Dựa trên kết quả huấn luyện, epoch thứ 13 được lựa chọn là mốc tốt nhất, với độ chính xác validation (89.11%) và giá trị mất mát thấp nhất (val_loss = 0.2751). Đây là phiên bản mô hình được lưu lại để phục vụ cho bước trích xuất đặc trưng và suy luận sau này.

Sau khi đã đánh giá hiệu suất tổng thể của mô hình thông qua các biểu đồ trực quan hóa về độ chính xác và hàm mất mát, tiếp tục tiến hành phân tích **ma trận nhầm lẫn** được chuẩn hóa theo tỷ lệ phần trăm Hình 4.7 để hiểu rõ hơn về cách thức mà mô hình phân loại các lớp.



Hình 4.7. Ma trận nhầm lẫn theo tỷ lệ từng lớp của ResNet50.

Dựa trên ma trận nhầm lẫn (Confusion Matrix) của ResNet50 Hình 4.7, mô hình đạt hiệu suất khá tốt với tỷ lệ dự đoán đúng trên từng lớp dao động trong khoảng 83%-95%, ngoại trừ lớp Others đạt 61% do số mẫu ít và không có đặc điểm nổi bật. Cụ thể, đối với các lớp như Charts và Photographs đạt độ chính xác rất cao, lần lượt là 92% và 95%. Đây là các lớp dễ nhận dạng hơn, có thể do chúng sở hữu các đặc điểm đặc trưng nổi bật và ít bị trùng lặp với các lớp khác. Lớp Maps cũng đạt độ chính xác cao 90%, tuy nhiên có một tỷ lệ nhỏ mẫu bị nhầm thành lớp Charts và System_Model.

Bên cạnh đó, lớp System_Model có độ chính xác thấp hơn (83%). Phần lớn nhầm lẫn xảy ra với lớp Charts cho thấy rằng các đặc điểm hình ảnh của chúng có sự tương đồng nhất định. Lớp Others có độ chính xác thấp nhất với 61%, có thể do lớp này chứa nhiều ảnh không có đặc trưng rõ ràng.

Nhìn chung, mô hình phân loại ảnh có khả năng phân biệt các lớp rõ ràng với độ chính xác cao, tuy nhiên, vẫn còn một số nhầm lẫn nhất định giữa các lớp có đặc điểm tương tự. Mô hình đã thể hiện khả năng học đặc trưng và khái quát hóa tốt trên dữ liệu kiểm thử, với hiệu suất cao và ổn định.

Sau khi hoàn tất việc huấn luyện mô hình, tiến hành đánh giá hiệu suất trên tập kiểm thử (test) qua Bảng 4.6. Bảng thể hiện các chỉ số đánh giá hiệu suất precision, recall, f1-score, accuracy, support (số lượng mẫu) cho từng lớp nhãn và cung cấp độ chính xác tổng thể và các trung bình có trọng số.

Bảng 4.6. Các chỉ số đánh giá hiệu suất mô hình ResNet50.

	Precision	Recall	F1-score	Accuracy	Support
Charts	0.92	0.92	0.92	0.95	154
Maps	0.76	0.90	0.83	0.98	21
Others	0.77	0.61	0.68	0.97	28
Photographs	0.98	0.95	0.96	0.97	177
System_Model	0.78	0.83	0.80	0.93	83
accuracy	0.90	0.90	0.90		0.90
macro avg	0.84	0.84	0.84		463
weighted avg	0.90	0.90	0.90		463

Độ chính xác theo từng lớp: Lớp “Charts” có độ chính xác 95% trên 154 ảnh. Lớp “Maps” có độ chính xác 98% trên 21 ảnh. Lớp “Others” có độ chính xác 97% trên 28 ảnh. Lớp “Photographs” có độ chính xác 97% trên 177 ảnh. Lớp “System_Model” có độ chính xác 93% trên 83 ảnh. Những con số này cho thấy mô hình này có hiệu suất rất tốt trên các lớp.

Độ chính xác tổng thể (accuracy) đạt 90% trên tập kiểm thử, đồng nghĩa với việc chỉ có 10% mẫu bị phân loại sai. Đây là một kết quả tốt, phản ánh rằng mô hình hoạt động ổn định và hiệu quả khi áp dụng vào dữ liệu chưa từng thấy trước đó.

Độ chính xác của dự đoán (Precision) trung bình (weighted avg) đạt 90% cho thấy mô hình có xu hướng dự đoán khá chính xác với đa số các lớp. Lớp “Photographs” và “Charts” có precision rất cao (0.98, 0.92) nghĩa là trong số các ảnh được dự đoán là

“Photographs” và dự đoán là “Charts” có 98% và 92% dự đoán đúng. Tuy nhiên, “Maps”, “Others” và “System_Model” có precision khá thấp (0.76, 0.77, 0.78) cho thấy mô hình thường dự đoán nhầm các lớp khác thành lớp này do các lớp này có ít mẫu.

Độ nhạy (Recall) trung bình (weighted avg) đạt 90% cho thấy mô hình có khả năng nhận diện tốt phần lớn các lớp. Lớp “Photographs” và “Charts” tiếp tục nổi bật với recall rất cao (0.95, 0.92) chứng tỏ mô hình ít bỏ sót các ảnh thuộc hai lớp này. Tuy nhiên, lớp “Others” chỉ đạt 0.61, cho thấy khả năng bao phủ của mô hình với lớp này còn hạn chế.

F1-score trung bình (weighted avg) đạt 90% cho thấy mô hình vừa có độ chính xác cao, vừa bao phủ tốt trên toàn bộ tập kiểm tra. Lớp “Photographs” đạt F1-score cao nhất 0.96 phản ánh sự ổn định và hiệu quả vượt trội trong việc nhận diện lớp này. Lớp “Others” đạt F1-score thấp nhất (0.68) cho thấy sự mất cân bằng trong precision và recall và cần được cải thiện.

Nhìn chung, ba mô hình phân loại ảnh trên thể hiện hiệu suất phân loại cao và ổn định trên hầu hết các lớp. Tuy nhiên, hiệu quả phân loại lớp Others còn hạn chế do đặc trưng không rõ ràng và dễ bị nhầm lẫn. Đây là điểm cần xem xét cải thiện bằng cách bổ sung thêm dữ liệu hoặc tăng cường đặc trưng riêng cho lớp này.

Để đánh giá và so sánh hiệu suất giữa các mô hình CNN được áp dụng trong bài toán phân loại ảnh, ba mô hình tiêu biểu gồm **InceptionV3**, **VGG16** và **ResNet50** đã được huấn luyện trên cùng một tập dữ liệu. Bảng 4.7 trình bày các chỉ số đánh giá gồm Precision, Recall và F1-Score của từng mô hình:

Bảng 4.7. So sánh các thông số mô hình.

CNN Models	Precision	Recall	F1-score
VGG16	0.9130	0.9114	0.9117
ResNet50	0.8983	0.8963	0.8962
InceptionV3	0.9389	0.9395	0.9388

Bảng so sánh 3 mô hình khi được huấn luyện trên cùng tập dữ liệu, kết quả cho thấy mô hình VGG16 và ResNet50 với các thông số Precision, Recall, F1 thấp hơn mô hình InceptionV3. Điều này cho thấy mô hình InceptionV3 có khả năng phân loại chính xác và toàn diện hơn. Mặc dù VGG16 và ResNet50 cũng cho kết quả khả quan nhưng với các chỉ số đánh giá này thì InceptionV3 là lựa chọn tối ưu trong bài toán.

4.2.4. Kết quả kiểm thử kịch bản 4: Kiểm thử phân loại ảnh và tính độ tương đồng.

Hệ thống phân loại ảnh

Choose File No file chosen

Chọn mô hình: VGG16

Chọn ngưỡng tương đồng: 90%

Phân loại ảnh

Hình 4.8. Giao diện hệ thống.

Hệ thống phân loại ảnh

Choose File 01-497-A-L...3_img_3.png

Chọn mô hình: InceptionV3

Chọn ngưỡng t

InceptionV3

VGG16

ResNet50

Phân loại ảnh

Hình 4.9. Chọn mô hình phân loại.

Hệ thống phân loại ảnh

Choose File 01-497-A-L...3_img_3.png

Chọn mô hình: InceptionV3


Chọn ngưỡng tương đồng: 90%

Phân loại ảnh

Hình 4.10. Chọn ngưỡng tương đồng.

Kết quả mô hình InceptionV3 :

Câu 1. Lý do vì sao anh/chị chọn đăng ký học phần?
65 câu trả lời



- A. Cảm thấy hứng thú với học phần qua tên gọi của học phần.
- B. Qua tìm hiểu nội dung trong đề cương chi tiết học phần.
- C. Qua tham khảo ý kiến của người học trước, được biết môn học có nhiều tính hướng thực tiễn hấp dẫn.
- D. Ý kiến khác:

Dự đoán: Charts

Xác suất: 100.00%

Ảnh tương đồng (>90.0)

STT	Ảnh	Tên file	Độ tương đồng (%)
1		25-5853-D-CAO THANH THUY-226-234_page_2_img_1.png	99.35%
2		25-5853-D-CAO THANH THUY-226-234_page_4_img_1.png	98.17%
3		25-5853-D-CAO THANH THUY-226-234_page_3_img_1.png	96.98%

Hình 4.11. Kết quả phân loại.

Mô tả kịch bản:

Người dùng truy cập vào hệ thống Hình 4.8 và chọn ảnh đầu vào.

Người dùng chọn mô hình phân loại Hình 4.9, chọn ngưỡng tương đồng Hình 4.10 và nhấn phân loại ảnh.

Hệ thống trả về ảnh đầu vào, nhãn phân loại, xác suất phân loại và danh sách các ảnh tương đồng lớn hơn ngưỡng được sắp xếp giảm dần Hình 4.11.

4.3. Tổng kết chương

Chương này tập trung vào việc mô tả tập dữ liệu và khái niệm các độ đo hiệu suất, đưa ra các kịch bản kiểm thử cũng như kết quả kiểm thử của các kịch bản. Kết quả kiểm thử cho thấy nghiên cứu đã thực hiện huấn luyện và tích hợp thành công vào hệ thống website cho phép người dùng có thể truy cập vào hệ thống, phân loại và tìm kiếm hình ảnh tương đồng nhanh.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

5.1.1. Kết quả đạt được.

Về lý thuyết: Qua quá trình nghiên cứu, nắm vững kiến trúc của mô hình CNN điển hình như InceptionV3, VGG16, ResNet50. Việc tìm hiểu kỹ các mô hình này giúp hiểu rõ hơn về quy trình huấn luyện mạng nơ-ron tích chập, từ việc chuẩn bị dữ liệu ảnh huấn luyện (trích xuất ảnh từ PDF), thiết lập và huấn luyện mô hình phân loại cho đến xây dựng hệ thống ứng dụng mô hình vào việc phân loại ảnh đầu vào và tính toán độ tương đồng giữa các ảnh.

Về thực tiễn: Hệ thống được xây dựng có khả năng phân loại ảnh thành 5 nhóm chính với độ chính xác cao, đồng thời có thể tính toán độ tương đồng giữa các ảnh dựa trên đặc trưng trích xuất từ mô hình học sâu. Việc này cho phép tìm được các ảnh có nội dung gần giống nhau trong cùng một nhãn, phục vụ tốt cho các bài toán lưu trữ và tìm kiếm ảnh tự động trong tài liệu số.

5.1.2. Hạn chế.

Mặc dù hệ thống đã đạt được kết quả khả quan trong việc phân loại và tính độ tương đồng ảnh, nhưng vẫn còn tồn tại một số hạn chế nhất định. Thứ nhất, tập dữ liệu sử dụng trong quá trình huấn luyện còn hạn chế về số lượng và chưa thật sự đa dạng, trong đó một số lớp dữ liệu chưa cân bằng, ảnh hưởng đến độ chính xác của mô hình. Thêm vào đó, mô hình InceptionV3, VGG16, và ResNet50 đều có kiến trúc sâu và số lượng tham số lớn, dẫn đến chi phí tính toán cao và khó triển khai trên các thiết bị hạn chế tài nguyên.

Ngoài ra, nghiên cứu hiện tại mới chỉ thực hiện đánh giá trên tập dữ liệu kiểm thử nội bộ, chưa có bước đánh giá trên dữ liệu thực tế ngoài phạm vi huấn luyện. Trong quá trình fine-tune, mô hình cũng chỉ được huấn luyện lại một phần, chưa khai thác toàn bộ tiềm năng của kiến trúc. Đặc biệt, một hạn chế khác là hệ thống chưa tích hợp cơ chế lưu trữ ảnh vào cơ sở dữ liệu ngay sau quá trình trích xuất từ PDF mà chỉ được lưu vào thư mục trên ổ đĩa cục bộ. Điều này khiến cho việc truy xuất, tìm kiếm hoặc tích hợp với các hệ thống khác còn hạn chế.

5.2. Hướng phát triển

Với những hạn chế kể trên, hệ thống cần được nghiên cứu, khắc phục và đưa ra những định hướng phát triển như sau:

Mở rộng và cân bằng tập dữ liệu: Giúp cải thiện độ chính xác của mô hình, đặc biệt là đối với những lớp dữ liệu chưa được cân bằng. Bổ sung thêm dữ liệu từ nhiều nguồn khác nhau và tăng cường tính đa dạng của dữ liệu sẽ giúp mô hình học được những đặc trưng phong phú hơn và cải thiện khả năng phân loại.

Tăng cường việc triển khai mô hình trên các thiết bị tài nguyên hạn chế: Với các mô hình như InceptionV3, VGG16 và ResNet50 có số lượng tham số lớn, cần nghiên cứu và triển khai các kỹ thuật nén mô hình (model pruning) hoặc sử dụng các mô hình học sâu nhẹ hơn như MobileNet hoặc EfficientNet để giảm chi phí tính toán, đồng thời vẫn giữ được hiệu quả phân loại. Việc tối ưu hóa mô hình cho các thiết bị di động và môi trường tính toán hạn chế là một bước đi quan trọng trong việc mở rộng khả năng ứng dụng.

Đánh giá trên dữ liệu thực tế: Để mô hình có thể đáp ứng được yêu cầu thực tế, cần tiến hành đánh giá trên tập dữ liệu ngoài phạm vi huấn luyện. Việc kiểm tra mô hình với các tình huống thực tế giúp đánh giá độ chính xác và khả năng tổng quát của mô hình khi áp dụng vào các bài toán thực tế, giúp cải thiện khả năng sử dụng của hệ thống trong các môi trường khác nhau.

Tối ưu hóa quy trình fine-tune: Quá trình fine-tune có thể được tối ưu hơn bằng cách huấn luyện lại toàn bộ mô hình, thay vì chỉ fine-tune một phần của mô hình. Việc này sẽ giúp khai thác tối đa tiềm năng của kiến trúc mạng nơ-ron và nâng cao độ chính xác cho mô hình.

Tích hợp cơ sở dữ liệu lưu trữ ảnh: Để cải thiện khả năng truy xuất và tìm kiếm ảnh sau quá trình trích xuất, cần phát triển một hệ thống cơ sở dữ liệu để lưu trữ ảnh. Việc tích hợp hệ thống lưu trữ ảnh vào cơ sở dữ liệu sẽ giúp dễ dàng quản lý và truy xuất ảnh, đồng thời có thể tích hợp hệ thống với các ứng dụng khác để mở rộng khả năng sử dụng.

Ứng dụng công nghệ học máy khác: Bên cạnh các mô hình CNN, có thể thử nghiệm và tích hợp thêm các phương pháp học máy khác như học chuyển giao (transfer learning) trên các mô hình đã được huấn luyện từ trước, hoặc thử nghiệm với các phương pháp học bán giám sát (semi-supervised learning) và học không giám sát (unsupervised learning) để cải thiện độ chính xác và khả năng phân loại trên những dữ liệu mới, chưa được gán nhãn.

TÀI LIỆU THAM KHẢO

- [1] Zhang, A., Lipton, Z. C., Li, M., & Smola, A. J. (2024). *Dive into deep learning* (Modern Convolutional Neural Network). Cambridge University Press. *Đắm mình vào học sâu — Đắm mình vào học sâu 0.14.4 documentation*. (n.d.). Truy cập từ <https://d2l.ai/vn.com/>.
- [2] *Tổng hợp các mô hình CNN nổi tiếng - Phần 1*. (n.d.). SIU AI Lab. Truy cập từ <https://ailab.siu.edu.vn/article/11/tong-hop-cac-mo-hinh-cnn-noi-tieng-phan-1>.
- [3] Khánh, P. Đ. (2020, 31/5). *Bài 38 - Các kiến trúc CNN hiện đại*. Khanh's Blog. <https://phamdinhhkhanh.github.io/2020/05/31/CNNHistory.html>.
- [4] Admin. (2025, April 3). *GoogleNet: Cột mốc đột phá trong lĩnh vực trí tuệ nhân tạo*. AICandy. <https://aicandy.vn/googlenet-cot-moc-dot-pha-trong-linh-vuc-tri-tue-nhan-tao/>.
- [5] Admin. (2025b, April 3). *Mô hình ResNet: Đột phá trong nhận diện hình ảnh*. AICandy. <https://aicandy.vn/mo-hinh-resnet-dot-pha-trong-nhan-dien-hinh-anh/>.
- [6] Khánh, P. Đ. (2019, 22/11). *Bài 17 - Thuật toán HOG (Histogram of oriented gradient)*. Khanh's Blog. <https://phamdinhhkhanh.github.io/2019/11/22/HOG.html>.
- [7] Admin. (2025a, April 3). *Convolutional Neural Networks (CNN) trong Deep Learning*. AICandy. <https://aicandy.vn/convolutional-neural-networks-cnn-trong-deep-learning/>.
- [8] Admin. (2025, April 20). *Các phương pháp đánh giá hiệu suất mô hình Machine learning*. AICandy. <https://aicandy.vn/cac-phuong-phap-danh-gia-hieu-suat-mo-hinh-machine-learning/>.
- [9] Blink. (2025, April 20). *Distance Measure Trong Machine Learning*. Viblo. <https://viblo.asia/p/distance-measure-trong-machine-learning-ByEZkopYZQ0>.